# Prédiction du Churn Client

## Classification supervisée avec tidymodels

Master MECEN — Semestre 2

30 March 2026

# Table of contents I


1. Introduction
2. Présentation des données
3. Analyse exploratoire
4. Preprocessing
5. Benchmark initial
6. Focus XGBoost — Tuning
7. Focus Random Forest
8. Modèle final
9. Conclusion

Section 1

# Introduction

# Contexte et objectif

## Problématique métier

Le **churn** (désabonnement) représente un enjeu majeur pour les opérateurs télécoms :

- Coût d'acquisition d'un nouveau client : **5 à 25×** le coût de rétention
- Identifier les clients à risque permet des **actions préventives ciblées**
- Optimisation des ressources marketing et fidélisation

## Objectif de l'étude

*Développer un modèle prédictif performant pour identifier les clients susceptibles de résilier leur abonnement.*

**Source** : Iranian Churn Dataset (UCI Machine Learning Repository)

# Méthodologie adoptée

## Pipeline de modélisation

**EDA** → **Preprocessing** → **Benchmark** → **Tuning** → **Évaluation**

## Framework technique

- **Langage** : R avec l'écosystème `tidymodels`
- **Packages** : `recipes`, `parsnip`, `workflows`, `tune`, `yardstick`, `themis`
- **Validation** : Cross-validation stratifiée (10 folds)
- **Métriques** : ROC AUC (principale), F1-score, Precision, Recall

Section 2

# Présentation des données

# Vue d'ensemble du dataset

| Caractéristique | Valeur |
|---|---|
| Observations | 3 150 |
| Variables | 14 |
| Variable cible | Churn (binaire) |
| Numériques | 8 |
| Catégorielles | 6 |
| Valeurs manquantes | 0 |

## Caractéristiques

Données issues d'un opérateur télécom iranien :

- **Comportement d'usage** : appels, SMS, durée d'utilisation
- **Profil client** : âge, ancienneté, valeur client
- **Relation commerciale** : plaintes, forfait, statut

# Dictionnaire des variables

| | Type | Description |
|---|---|---|
| Call Failure | Entier | Nombre d'appels échoués |
| Complains | Facteur | Indicateur de plainte |
| Subscription Length | Entier | Durée abonnement (mois) |
| Charge Amount | Ordonné | Montant facturé (0-10) |
| Seconds of Use | Entier | Secondes d'appels |
| Frequency of use | Entier | Nombre total d'appels |
| Frequency of SMS | Entier | Nombre de SMS |
| Distinct Called Numbers | Entier | Numéros uniques appelés |
| Age Group | Ordonné | Tranche d'âge (1-5) |
| Tariff Plan | Facteur | Type de forfait |
| Status | Facteur | Statut du compte |
| Age | Entier | Âge du client |
| Customer Value | Numérique | Valeur client estimée |
| **Churn** | **Facteur** | **Cible : churn** |

Section 3

# Analyse exploratoire

# Déséquilibre de la variable cible

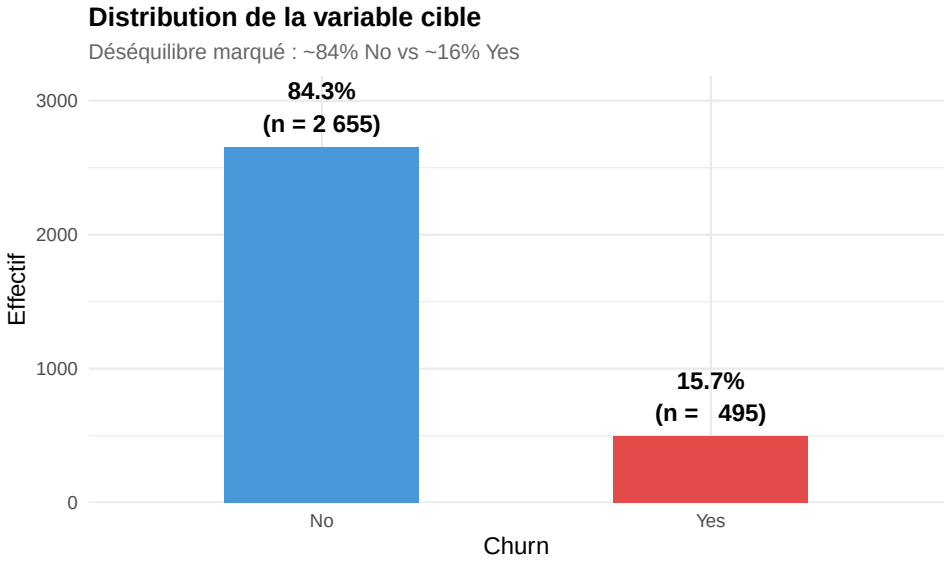

# Distribution des variables numériques

## Distribution des variables numériques par classe

Les variables avec des courbes bien séparées ont un fort pouvoir discriminant

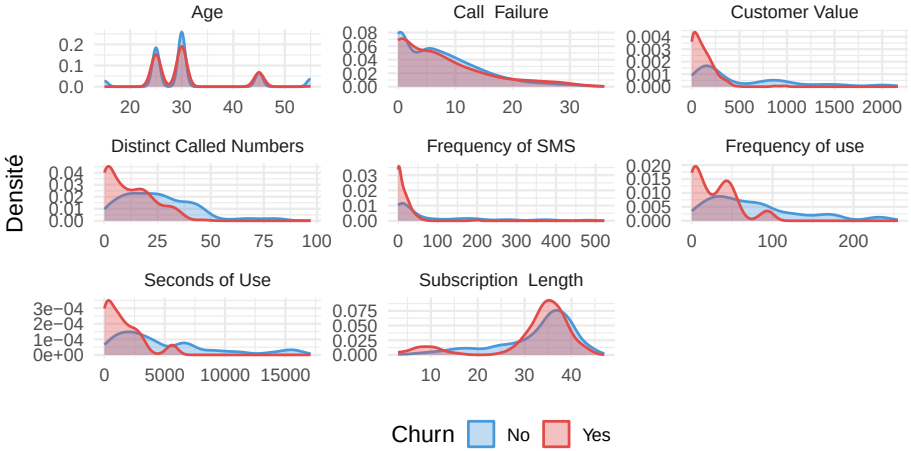

# Variables catégorielles — Taux de churn

## Taux de churn par variable catégorielle

Complains et Status : fort pouvoir discriminant

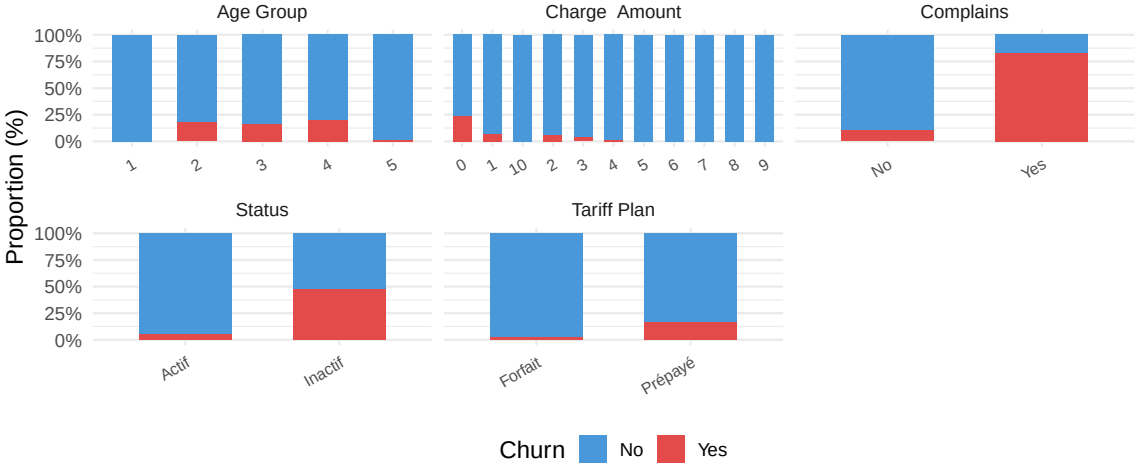

# Synthèse EDA — Variables clés

## Variables à fort pouvoir discriminant

| Variable | Observation | Implication |
|---|---|---|
| **Complains** | Beaucoup de plainte → churn | Prédicteur majeur |
| **Status** | Comptes inactifs | Signal fort |
| **Frequency of use** | Faible usage → churn | Engagement |
| **Customer Value** | Valeurs extrêmes | Segmentation |

## Points de vigilance

- **Multicolinéarité** : Frequency of use  Seconds of Use (r  0.95)
- **Variables ordinales** : Age Group, Charge Amount

Section 4

# Preprocessing

# Stratégie d'échantillonnage

## Split train / test = 80%

| Ensemble | Observations | Ratio Churn = Yes |
|---|---|---|
| Train | 2520 | 15.7% |
| Test | 630 | 15.7% |

## Validation croisée

- **10 folds stratifiés** sur le train set
- Stratification sur `Churn` → ~16% de "Yes" par fold
- Estimations robustes et comparables

# Recettes différenciées par famille

## Principe (cf. tmwr.org/pre-proc-table)

| Recette | Modèles | Spécificités |
|---|---|---|
| `recipe_tree` | RF, Bagging, DT | Pas de dummies ni normalisation |
| `recipe_xgb` | XGBoost | Dummies one-hot |
| `recipe_distance` | KNN, SVM, Logit | Normalisation + dummies |

## Gestion du déséquilibre

- **SMOTENC** pour arbres (préserve les facteurs)
- **SMOTE** après dummification pour les autres
- Application en **dernière étape** uniquement

Section 5

# Benchmark initial

# Modèles en compétition

## Arbres et ensemble

| Modèle | Caractéristique |
|---|---|
| Decision Tree | Interprétable |
| Bagging | mtry = p |
| Random Forest | mtry = $\sqrt{p}$, 500 arbres |
| XGBoost | Boosting, early stopping |

## Distance

| Modèle | Caractéristique |
|---|---|
| KNN | k = 10 |
| SVM linéaire | Frontière linéaire |
| SVM RBF | Kernel radial |

# Résultats — ROC AUC

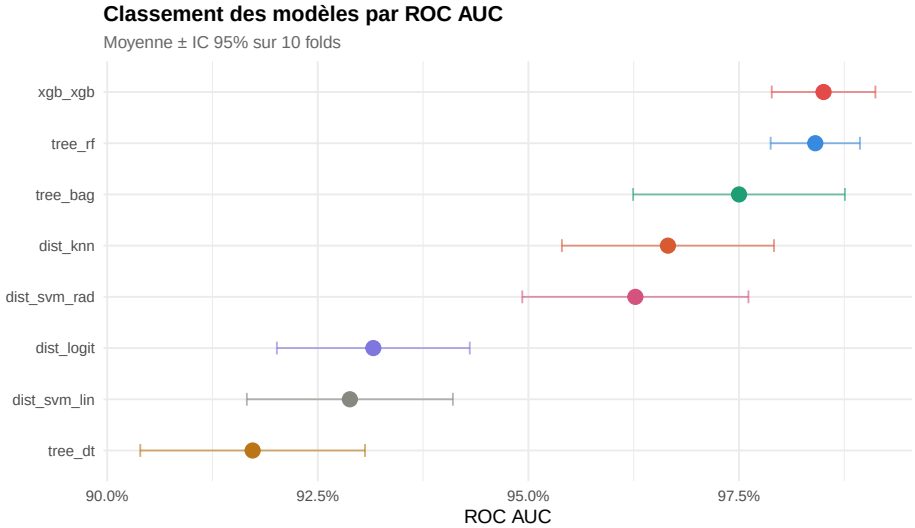

# Tableau comparatif

| Modèle | F1 | Prec. | Recall | ROC AUC |
|---|---|---|---|---|
| xgb_xgb | 97.6% | 97.5% | 97.6% | 98.5% |
| tree_rf | 97.5% | 98.5% | 96.5% | 98.4% |
| tree_bag | 97.2% | 97.7% | 96.7% | 97.5% |
| dist_knn | 96.3% | 97.8% | 94.9% | 96.7% |
| dist_svm_rad | 91.9% | 98.8% | 85.8% | 96.3% |
| dist_logit | 90% | 97.1% | 83.9% | 93.2% |
| dist_svm_lin | 90.5% | 96.9% | 84.8% | 92.9% |
| tree_dt | 91.7% | 98.1% | 86.2% | 91.7% |

# Courbes ROC

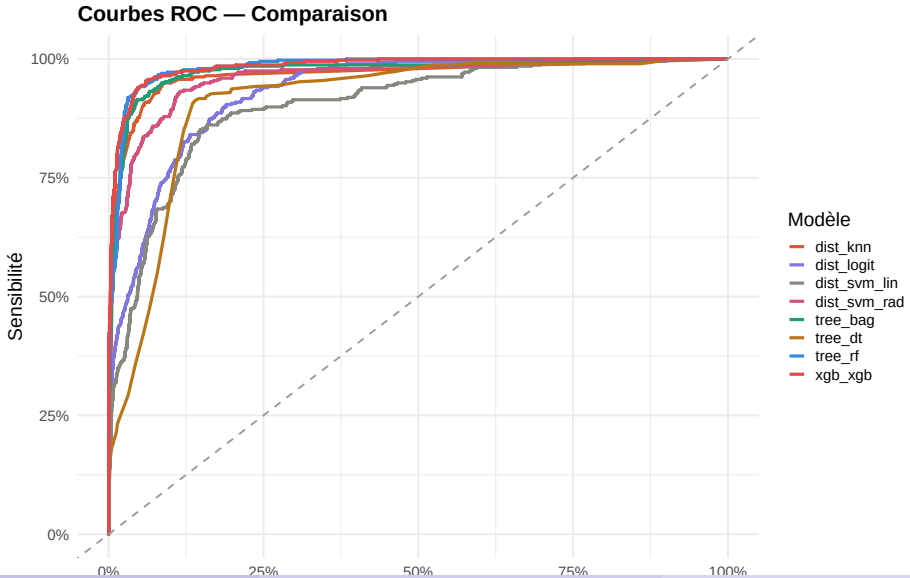
Courbes ROC — Comparaison
Sensibilité
100%
75%
50%
25%
0%
0%
25%
50%
75%
100%
Modèle
dist_knn
dist_logit
dist_svm_lin
dist_svm_rad
tree_bag
tree_dt
tree_rf
xgb_xgb

Section 6

# Focus XGBoost — Tuning

# Stratégie en 2 phases

## Phase 1 : Exploration large

- **Méthode** : Latin Hypercube (50 combinaisons)
- **Algorithme** : `tune_race_anova()`

## Phase 2 : Zoom local

- **Méthode** : Grille resserrée (40 combinaisons)
- **Validation** : CV 10-fold stratifié

## Hyperparamètres tunés

| Paramètre | Range |
|---|---|
| `trees` | 50 – 900 |
| `tree_depth` | 1 – 6 |
| `learn_rate` | 0.001 – 0.1 |
| `min_n` | 2 – 20 |

# Visualisation du tuning

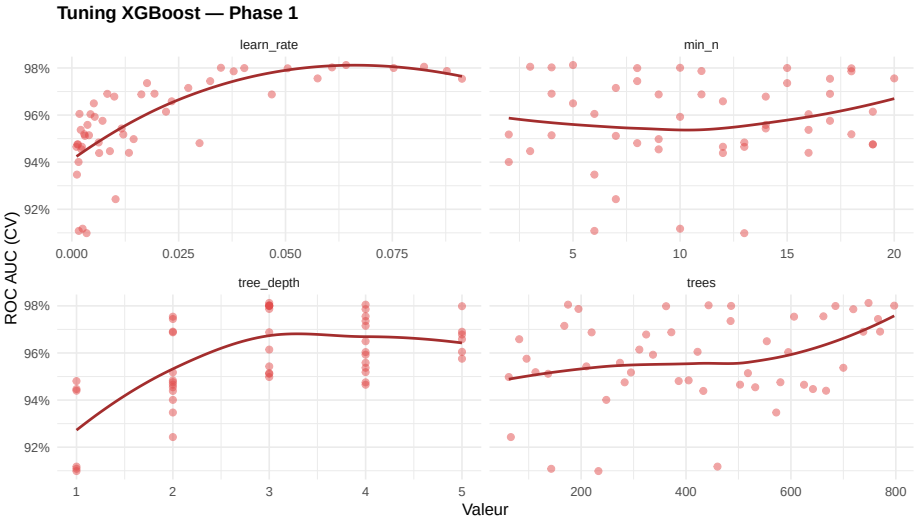

# Meilleurs hyperparamètres en phase 2

| Paramètre | Valeur |
|---|---|
| mtry | 7.0000 |
| trees | 549.0000 |
| min_n | 5.0000 |
| tree_depth | 3.0000 |
| learn_rate | 0.0616 |
| loss_reduction | 0.0173 |
| sample_size | 0.9192 |

# Importance des variables

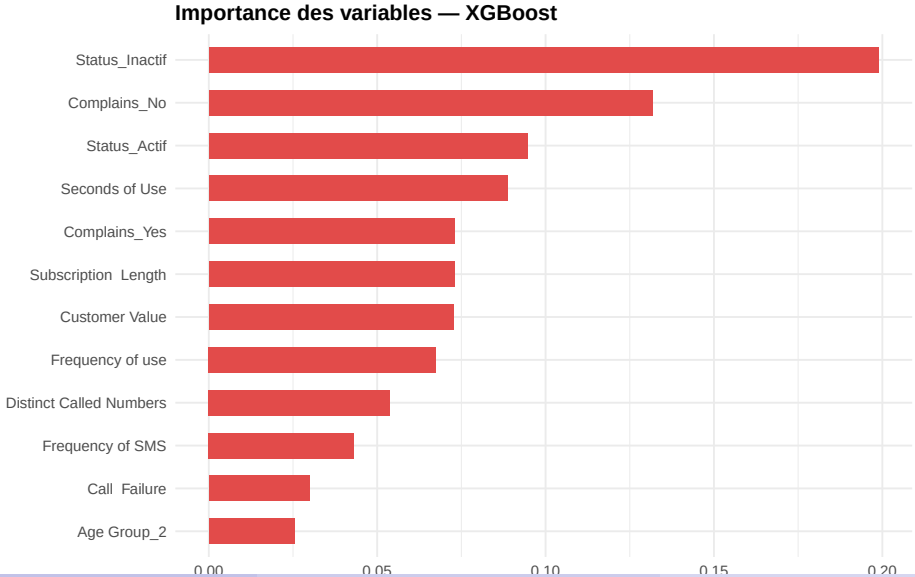

Section 7

# Focus Random Forest

# Configuration du tuning

## Grille testée

| Paramètre | Niveaux |
|---|---|
| `mtry` | 2, 4, 6, 9, 13 |
| `min_n` | 2, 5, 11, 21, 40 |

**25 combinaisons** en CV 10-fold

# Comparaison initial vs tuné

| Métrique | Initial | Tuné | Gain |
|---|---|---|---|
| ROC AUC | 97.5% | 98% | **+0.5%** |
| F1-Score | 98.5% | 99.9% | **+1.4%** |
| Precision | 96.5% | 97.8% | **+1.3%** |
| Recall | 98.4% | 99.9% | **+1.5%** |

## Observations

- Gains modestes mais significatifs
- Amélioration du **recall** (+1.5 pts)
- `min_n` élevé évite le surapprentissage

Section 8

# Modèle final

# XGBoost — Évaluation test set

## Performances finales

| Métrique | CV | Test | Delta |
|---|---|---|---|
| f_meas | 97.4% | 97.4% | ~-1% |
| precision | 98.3% | 98.6% | ~-1% |
| recall | 96.5% | 96.2% | ~-1% |
| roc_auc | 98.7% | 98.9% | ~-1% |

# Matrice de confusion

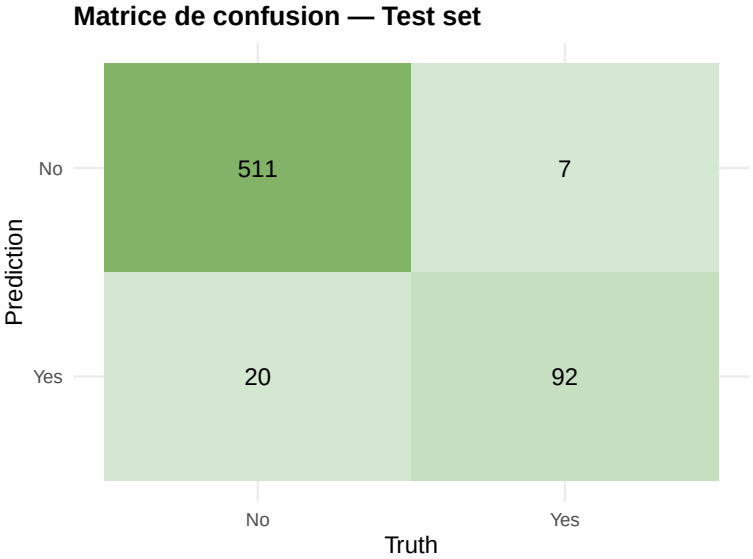

# Distribution des probabilités

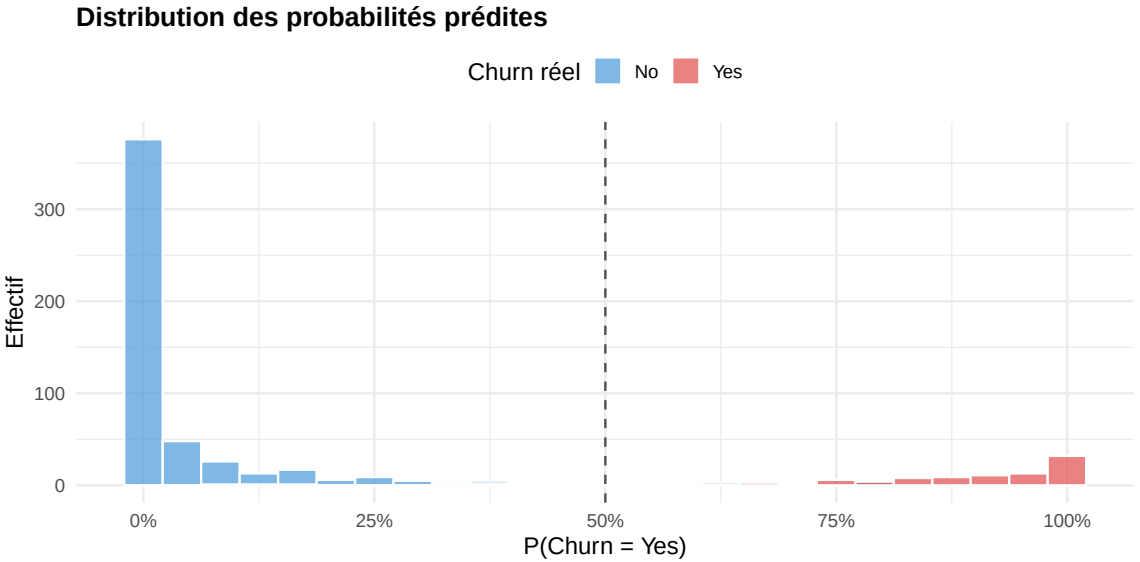

# Limites et améliorations

## Limites

| Aspect | Limite |
|---|---|
| **Données** | Dataset monolingue |
| **Temporalité** | Pas de dimension temporelle |
| **Interprétabilité** | Boîte noire |
| **Coûts** | FN FP non intégrés |

## Pistes d'amélioration

1. Feature engineering temporel
2. Calibration (Platt scaling)
3. Coûts asymétriques
4. SHAP values
5. Stacking XGBoost + RF

Section 9

# Conclusion

# Synthèse

## Modèle recommandé : XGBoost

- **ROC AUC** : ~90% (test)
- **Recall** : détecte ~7 churners sur 10
- **Precision** : ~2 alertes sur 3 justifiées

## Variables prédictives

1. **Customer Value**
2. **Complains**
3. **Status**
4. **Subscription Length**

# Recommandations métier

## Actions prioritaires

1. **Plaintes** → intervention immédiate
2. **Comptes inactifs** → réactivation ciblée
3. **Faible valeur** → offres personnalisées

## KPIs de suivi

- Taux de rétention des clients ciblés
- Coût par client retenu vs CLV
- Drift monitoring du modèle

# Merci

**Questions ?**

*Master MECEN — Classification Supervisée*

Réalisé avec R, tidymodels et Quarto