Prédiction du Churn Client

Classification supervisée avec tidymodels

Master MECEN — Semestre 2

28 March 2026

Table of contents I

1. Introduction
2. Présentation des données
3. Analyse exploratoire
4. Preprocessing
5. Benchmark initial
6. Focus XGBoost — Tuning
7. Focus Random Forest
8. Modèle final
9. Conclusion

Section 1

Introduction

Contexte et objectif

Problématique métier

Le **churn** (désabonnement) représente un enjeu majeur pour les opérateurs télécoms :

- Coût d'acquisition d'un nouveau client : **5 à 25×** le coût de rétention
- Identifier les clients à risque permet des **actions préventives ciblées**
- Optimisation des ressources marketing et fidélisation

Objectif de l'étude

Développer un modèle prédictif performant pour identifier les clients susceptibles de résilier leur abonnement.

Source : Iranian Churn Dataset (UCI Machine Learning Repository)

Méthodologie adoptée

Pipeline de modélisation

EDA → **Preprocessing** → **Benchmark** → **Tuning** → **Évaluation**

Framework technique

- **Langage** : R avec l'écosystème `tidymodels`
- **Packages** : `recipes`, `parsnip`, `workflows`, `tune`, `yardstick`, `themis`
- **Validation** : Cross-validation stratifiée (10 folds)
- **Métriques** : ROC AUC (principale), F1-score, Precision, Recall

Section 2

Présentation des données

Vue d'ensemble du dataset

Caractéristique	Valeur
Observations	3 150
Variables	14
Variable cible	Churn (binaire)
Numériques	8
Catégorielles	6
Valeurs manquantes	0

Caractéristiques

Données issues d'un opérateur télécom iranien :

- **Comportement d'usage** : appels, SMS, durée d'utilisation
- **Profil client** : âge, ancienneté, valeur client
- **Relation commerciale** : plaintes, forfait, statut

Dictionnaire des variables

	Type	Description
Call Failure	Entier	Nombre d'appels échoués
Complains	Facteur	Indicateur de plainte
Subscription Length	Entier	Durée abonnement (mois)
Charge Amount	Ordonné	Montant facturé (0-10)
Seconds of Use	Entier	Secondes d'appels
Frequency of use	Entier	Nombre total d'appels
Frequency of SMS	Entier	Nombre de SMS
Distinct Called Numbers	Entier	Numéros uniques appelés
Age Group	Ordonné	Tranche d'âge (1-5)
Tariff Plan	Facteur	Type de forfait
Status	Facteur	Statut du compte
Age	Entier	Âge du client
Customer Value	Numérique	Valeur client estimée
Churn	**Facteur**	**Cible : churn**

Section 3

Analyse exploratoire

Déséquilibre de la variable cible

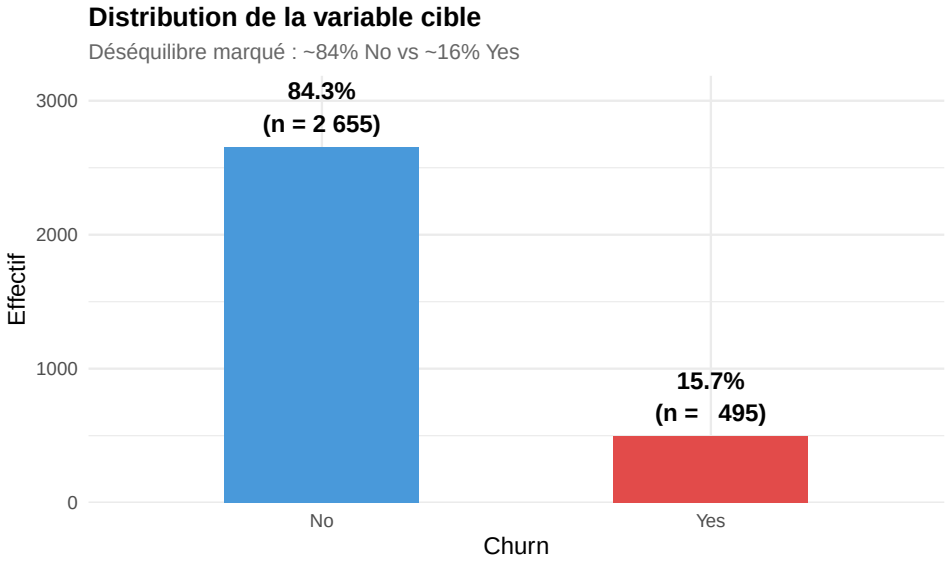

Statistiques descriptives — Variables numériques

Variable	Min	Médiane	Moyenne	Max	E.T.
Age	15	30.00	31.0	55.00	8.8
Call Failure	0	6.00	7.6	36.00	7.3
Customer Value	0	228.48	471.0	2165.28	517.0
Distinct Called Numbers	0	21.00	23.5	97.00	17.2
Frequency of SMS	0	21.00	73.2	522.00	112.2
Frequency of use	0	54.00	69.5	255.00	57.4
Seconds of Use	0	2990.00	4472.5	17090.00	4197.9
Subscription Length	3	35.00	32.5	47.00	8.6

Variables discriminantes — Corrélations

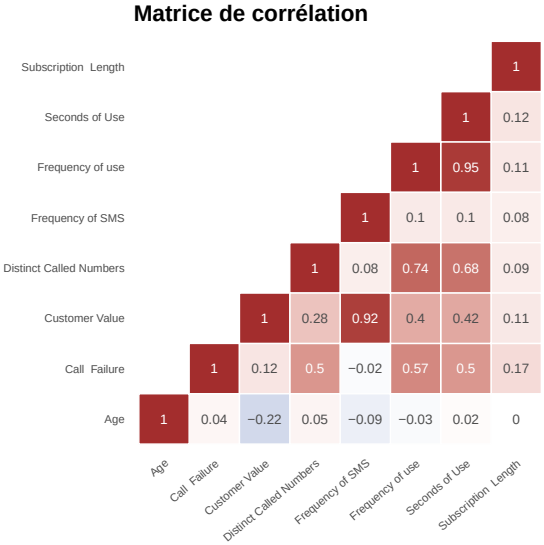

Variables catégorielles — Taux de churn

Taux de churn par variable catégorielle

Complains et Status : fort pouvoir discriminant

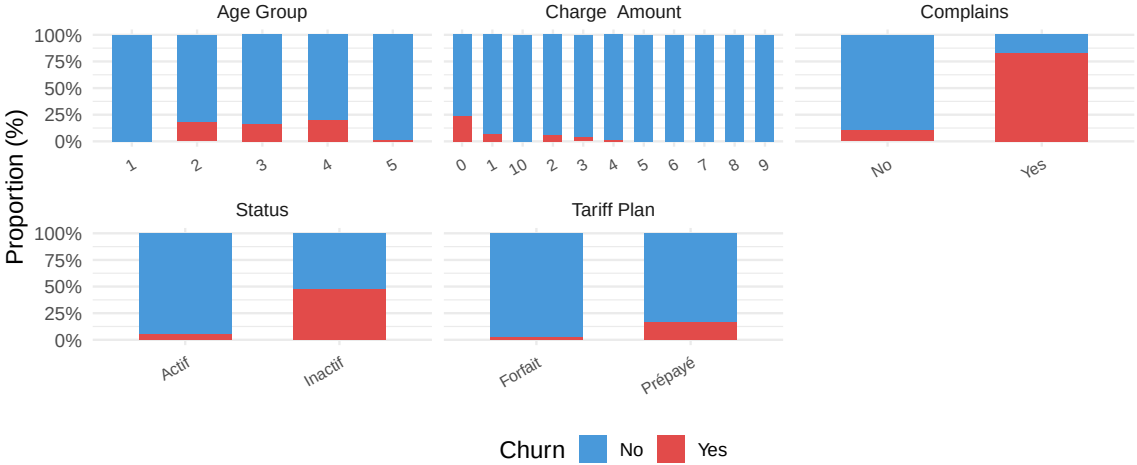

Synthèse EDA — Variables clés

Variables à fort pouvoir discriminant

Variable	Observation	Implication
Complains	Beaucoup de plainte → churn	Prédicteur majeur
Status	Comptes inactifs	Signal fort
Frequency of use	Faible usage → churn	Engagement
Customer Value	Valeurs extrêmes	Segmentation

Points de vigilance

- **Multicolinéarité** : Frequency of use Seconds of Use (r 0.95)
- **Variables ordinales** : Age Group, Charge Amount

Section 4

Preprocessing

Stratégie d'échantillonnage

Split train / test = 80%

Ensemble	Observations	Ratio Churn = Yes
Train	2520	15.7%
Test	630	15.7%

Validation croisée

- **10 folds stratifiés** sur le train set
- Stratification sur `Churn` → ~16% de "Yes" par fold
- Estimations robustes et comparables

Recettes différenciées par famille

Principe (cf. tmwr.org/pre-proc-table)

Recette	Modèles	Spécificités
`recipe_tree`	RF, Bagging, DT	Pas de dummies ni normalisation
`recipe_xgb`	XGBoost	Dummies one-hot
`recipe_distance`	KNN, SVM, Logit	Normalisation + dummies

Gestion du déséquilibre

- **SMOTENC** pour arbres (préserve les facteurs)
- **SMOTE** après dummification pour les autres
- Application en **dernière étape** uniquement

Section 5

Benchmark initial

Modèles en compétition

Arbres et ensemble

Modèle	Caractéristique
Decision Tree	Interprétable
Bagging	mtry = p
Random Forest	mtry = $\sqrt{p}$, 500 arbres
XGBoost	Boosting, early stopping

Distance

Modèle	Caractéristique
KNN	k = 10
SVM linéaire	Frontière linéaire
SVM RBF	Kernel radial

Résultats — ROC AUC

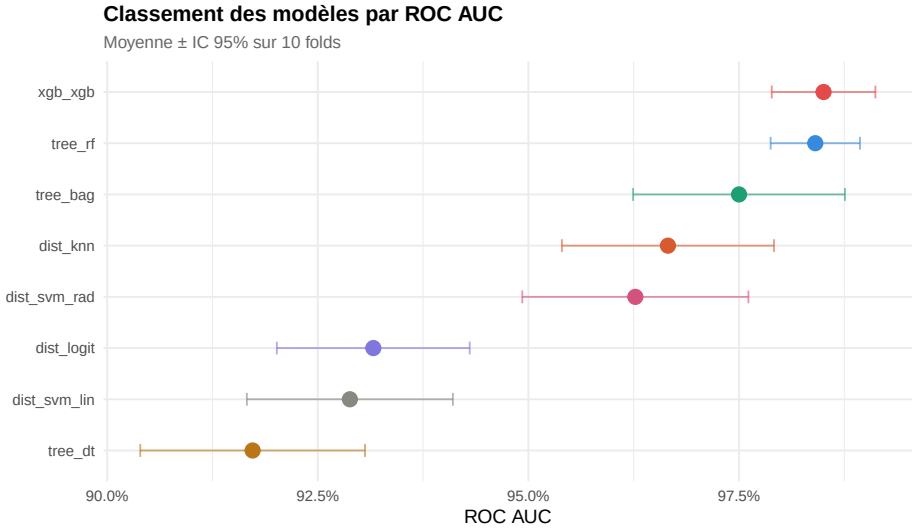

Tableau comparatif

Modèle	F1	Prec.	Recall	ROC AUC
xgb_xgb	97.6%	97.5%	97.6%	98.5%
tree_rf	97.5%	98.5%	96.5%	98.4%
tree_bag	97.2%	97.7%	96.7%	97.5%
dist_knn	96.3%	97.8%	94.9%	96.7%
dist_svm_rad	91.9%	98.8%	85.8%	96.3%
dist_logit	90%	97.1%	83.9%	93.2%
dist_svm_lin	90.5%	96.9%	84.8%	92.9%
tree_dt	91.7%	98.1%	86.2%	91.7%

Courbes ROC

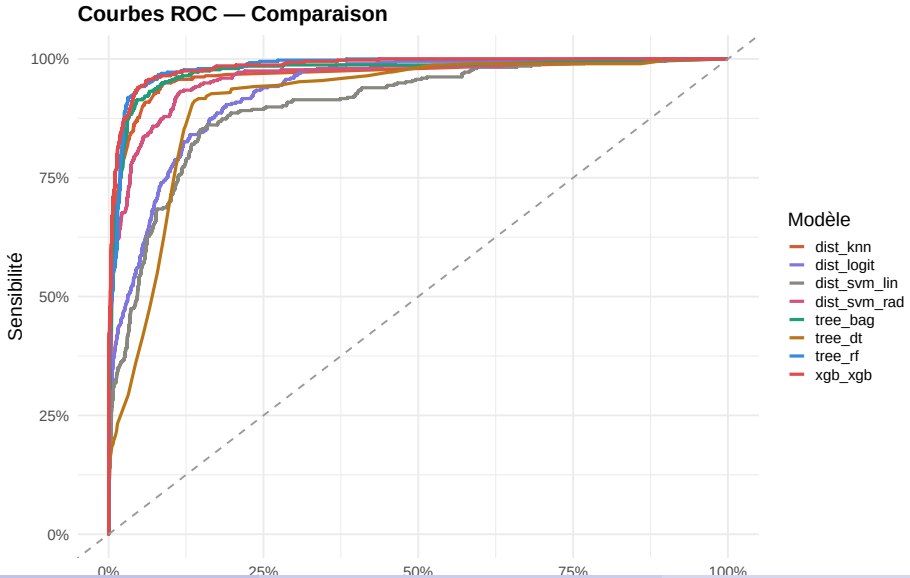
Courbes ROC — Comparaison
Sensibilité
100%
75%
50%
25%
0%
0%
25%
50%
75%
100%
Modèle
dist_knn
dist_logit
dist_svm_lin
dist_svm_rad
tree_bag
tree_dt
tree_rf
xgb_xgb

Section 6

Focus XGBoost — Tuning

Stratégie en 2 phases

Phase 1 : Exploration large

- **Méthode** : Latin Hypercube (50 combinaisons)
- **Algorithme** : `tune_race_anova()`

Phase 2 : Zoom local

- **Méthode** : Grille resserrée (40 combinaisons)
- **Validation** : CV 10-fold stratifié

Hyperparamètres tunés

Paramètre	Range
`trees`	50 – 900
`tree_depth`	1 – 6
`learn_rate`	0.001 – 0.1
`min_n`	2 – 20

Visualisation du tuning

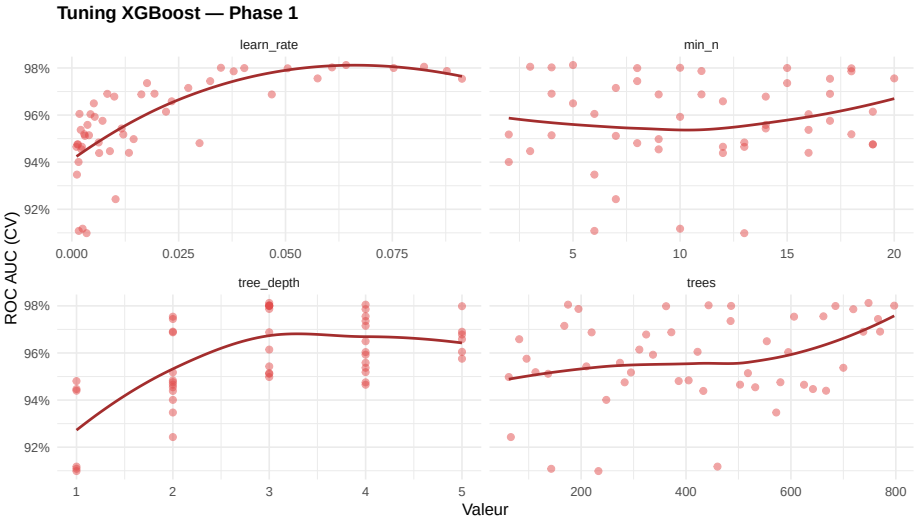

Meilleurs hyperparamètres en phase 2

Paramètre	Valeur
mtry	7.0000
trees	549.0000
min_n	5.0000
tree_depth	3.0000
learn_rate	0.0616
loss_reduction	0.0173
sample_size	0.9192

Importance des variables

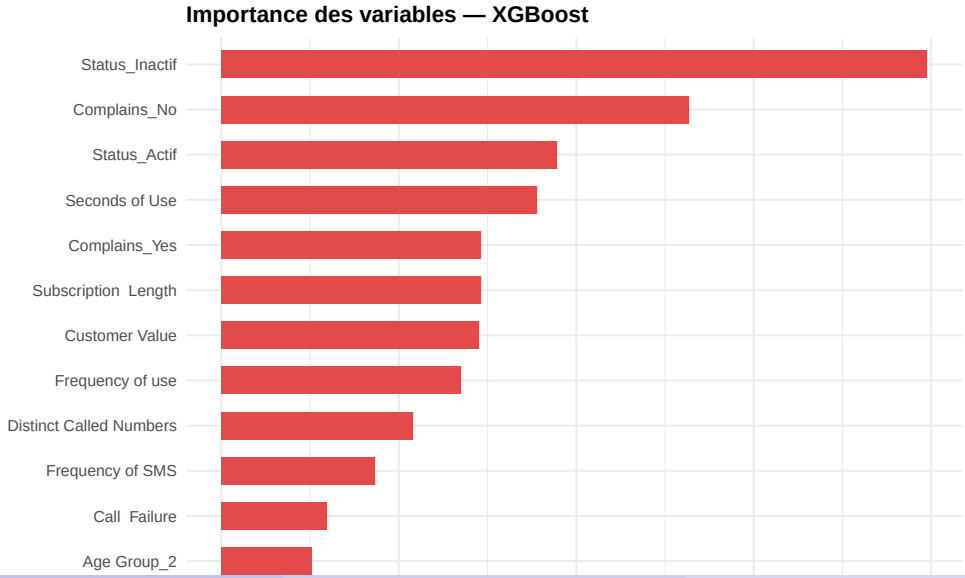

Section 7

Focus Random Forest

Configuration du tuning

Spécification

```
rf_spec <- rand_forest(
  mtry  = tune(),
  min_n = tune(),
  trees = 1000
) |>
  set_engine("ranger", importance = "permutation")
```

Grille testée

Paramètre	Niveaux
`mtry`	2, 4, 6, 9, 13
`min_n`	2, 5, 11, 21, 40

25 combinaisons en CV 10-fold

Comparaison initial vs tuné

Métrique	Initial	Tuné	Gain
ROC AUC	97.5%	98%	**+0.5%**
F1-Score	98.5%	99.9%	**+1.4%**
Precision	96.5%	97.8%	**+1.3%**
Recall	98.4%	99.9%	**+1.5%**

Observations

- Gains modestes mais significatifs
- Amélioration du **recall** (+1.5 pts)
- `min_n` élevé évite le surapprentissage

Section 8

Modèle final

XGBoost — Évaluation test set

Performances finales

Métrique	CV	Test	Delta
f_meas	97.4%	97.4%	~-1%
precision	98.3%	98.6%	~-1%
recall	96.5%	96.2%	~-1%
roc_auc	98.7%	98.9%	~-1%

Matrice de confusion

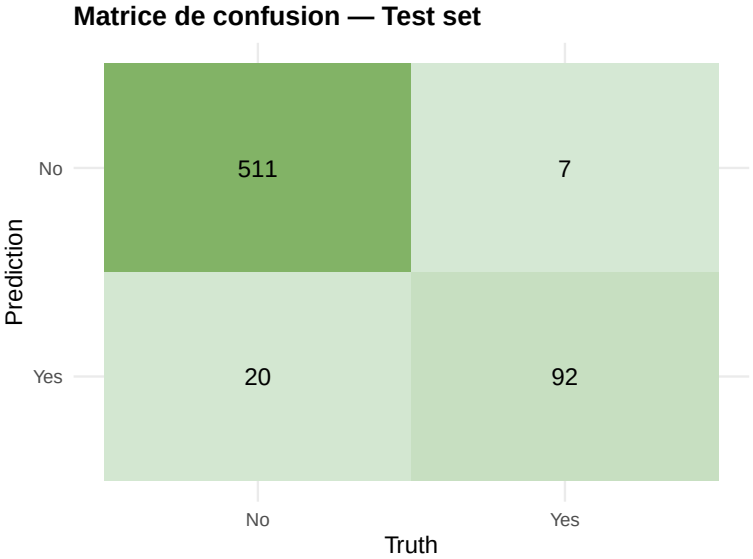

Distribution des probabilités

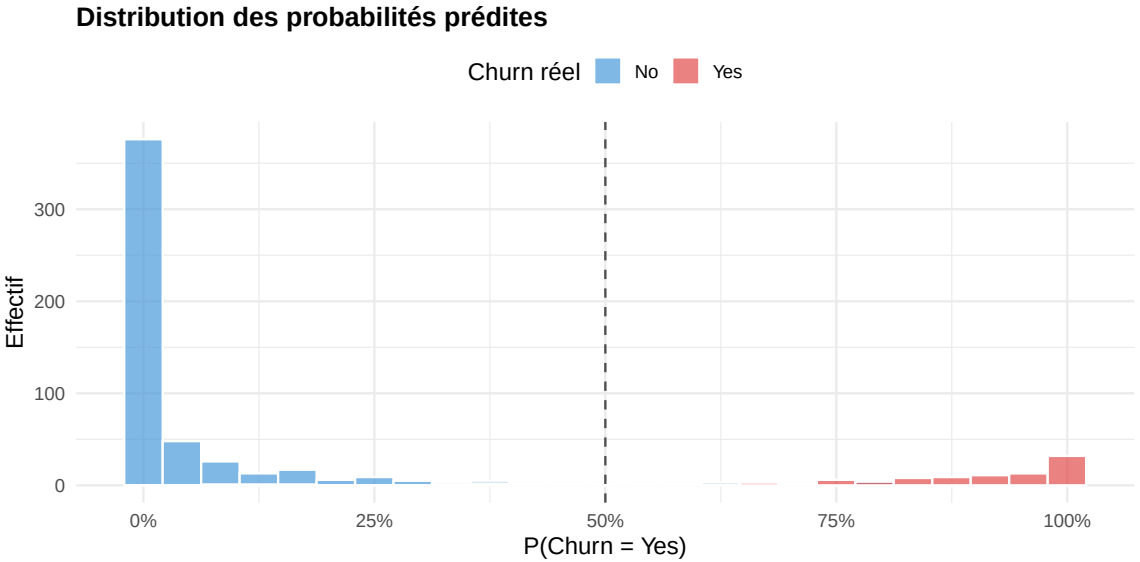

Limites et améliorations

Limites

Aspect	Limite
Données	Dataset monolingue
Temporalité	Pas de dimension temporelle
Interprétabilité	Boîte noire
Coûts	FN FP non intégrés

Pistes d'amélioration

1. Feature engineering temporel
2. Calibration (Platt scaling)
3. Coûts asymétriques
4. SHAP values
5. Stacking XGBoost + RF

Section 9

Conclusion

Synthèse

Modèle recommandé : XGBoost

- **ROC AUC** : ~90% (test)
- **Recall** : détecte ~7 churners sur 10
- **Precision** : ~2 alertes sur 3 justifiées

Variables prédictives

1. **Customer Value**
2. **Complains**
3. **Status**
4. **Subscription Length**

Recommandations métier

Actions prioritaires

1. **Plaintes** → intervention immédiate
2. **Comptes inactifs** → réactivation ciblée
3. **Faible valeur** → offres personnalisées

KPIs de suivi

- Taux de rétention des clients ciblés
- Coût par client retenu vs CLV
- Drift monitoring du modèle

Merci

Questions ?

Master MECEN — Classification Supervisée

Réalisé avec R, tidymodels et Quarto