Prédiction du churn client dans le secteur des télécommunications

Étude comparative de dix modèles de classification supervisée avec *tidymodels*

Barthélémy Bastien et Fadli Aaron

2 mai 2026

Résumé

La prédiction du désabonnement client (churn) constitue un enjeu stratégique majeur pour les opérateurs de télécommunications. Ce rapport présente une étude comparative de dix algorithmes de classification supervisée appliquée à l'Iranian Churn Dataset (3 150 observations, 13 prédicteurs), un jeu de données caractérisé par un déséquilibre de classes marqué (environ 16 % de churners). La méthodologie repose sur le cadre algorithmique, augmentation synthétique par SMOTE, validation croisée stratifiée à dix plis, et optimisation des hyperparamètres par échantillonnage Latin Hypercube combiné à la course ANOVA (tune_race_anova). Les dix modèles évalués couvrent les et quadratique, méthodes à noyau (SVM linéaire et RBF), k plus proches voisins, arbres de décision, méthodes ensemblistes (forêt aléatoire, bagging, XGBoost) et régression logistique. Les résultats révèlent une supériorité nette des méthodes ensemblistes, confirmée par l'évaluation finale sur l'ensemble de test qui atteste d'une bonne capacité de généralisation sans surapprentissage significatif. tidymodels sous R : quatre recettes de prétraitement adaptées à chaque famille principales familles de la classification supervisée : analyse discriminante linéaire

Table des matières

1 Introduction **4**
1.1 Contexte économique et enjeux du churn . . . 4
1.2 Problématique et objectifs . . . 4

2 Données et analyse exploratoire **5**
2.1 Description du jeu de données . . . 5
2.2 Déséquilibre de la variable cible . . . 5
2.3 Principaux enseignements exploratoires . . . 6

3 Méthodologie **7**
3.1 Partitionnement des données . . . 7
3.2 Prétraitement des données . . . 7
3.2.1 Principes généraux . . . 7
3.2.2 Quatre recettes spécialisées . . . 7
3.3 Modèles de classification . . . 8
3.3.1 Vue d'ensemble des dix modèles . . . 8
3.3.2 Description des algorithmes . . . 8
3.4 Protocole d'évaluation . . . 9
3.4.1 Métriques de performance . . . 9

4 Benchmark initial **10**
4.1 Tableau des métriques . . . 10
4.2 Courbes ROC comparatives . . . 11

5 Optimisation des hyperparamètres **12**
5.1 Stratégie de tuning . . . 12
5.2 Résultats du tuning . . . 12
5.3 Courbes ROC après tuning . . . 13

6 Évaluation finale sur le jeu de test **14**
6.1 Comparaison validation croisée vs. jeu de test . . . 14
6.2 Métriques finales sur le jeu de test . . . 14
6.3 Courbe ROC et matrice de confusion finales . . . 15
6.4 Importance des variables . . . 16

7 Discussion **17**
7.1 Synthèse des résultats . . . 17
7.2 Limites méthodologiques . . . 17
7.3 Perspectives d'amélioration . . . 18

8 Conclusion **19**

9 Références **20**

Annexe A : Données **21**
Dictionnaire des variables . . . 21
Statistiques descriptives . . . 21

Annexe B : Analyse exploratoire approfondie **23**

Annexe C : Paramètres d'optimisation **27**
Espaces de recherche . . . 27

Hyperparamètres optimaux 27

Annexe D : Résultats complémentaires — Benchmark initial **28**

Annexe E : Résultats complémentaires — Tuning **30**

1 Introduction

1.1 Contexte économique et enjeux du churn

Dans un marché des télécommunications caractérisé par une saturation croissante et une concurrence accrue, la fidélisation des clients représente un levier de rentabilité déterminant. Le *churn* - ou désabonnement - désigne le phénomène par lequel un client met fin à sa relation contractuelle avec un opérateur pour migrer vers un concurrent ou cesser de souscrire à un service. Les études sectorielles estiment que le coût d'acquisition d'un nouveau client est plusieurs fois supérieur au coût de fidélisation d'un client existant. L'enjeu de la prédiction du churn est donc double : identifier les clients à risque avant leur départ effectif, et déclencher des actions de rétention ciblées et personnalisées.

La modélisation prédictive du churn s'inscrit dans la problématique plus large du *Customer Relationship Management* (CRM). Elle vise à attribuer, pour chaque client, une probabilité de départ fondée sur ses caractéristiques comportementales, d'usage et contractuelles. Cette approche permet de segmenter la clientèle selon son niveau de risque et d'optimiser l'allocation des ressources marketing.

D'un point de vue technique, la prédiction du churn constitue un problème de **classification binaire supervisée** : la variable cible prend deux valeurs (churn / non-churn), et l'objectif est d'apprendre une règle de décision à partir d'observations labellisées. Ce problème présente toutefois plusieurs défis spécifiques : le déséquilibre des classes (les churners sont généralement minoritaires), la colinéarité potentielle des prédicteurs, et la nécessité d'une bonne généralisation sur des données futures.

1.2 Problématique et objectifs

Ce rapport s'inscrit dans le cadre du Master MECEN de l'Université de Tours. L'objectif principal est de **comparer les performances de dix algorithmes de classification supervisée** sur la prédiction du churn client, à partir de l'Iranian Churn Dataset mis à disposition par l'**UC Irvine Machine Learning Repository**.

Quatre questions de recherche structurent l'analyse :

1. Quels modèles offrent les meilleures performances de discrimination entre clients churners et non-churners, avec leurs hyperparamètres par défaut ?
2. Dans quelle mesure l'optimisation systématique des hyperparamètres améliore-t-elle les performances relatives des modèles ?
3. Le modèle sélectionné généralise-t-il correctement à des données inédites, sans surapprentissage ?
4. Quelles variables jouent le rôle le plus déterminant dans la prédiction du churn ?

2 Données et analyse exploratoire

2.1 Description du jeu de données

[L'*Iranian Churn Dataset](https://archive.ics.uci.edu/dataset/563/iranian+churn+dataset)* a été collecté auprès d'un opérateur de téléphonie iranien sur une période de douze mois. Il comprend **3150 observations** et **14 variables**, 13 prédicteurs et une variable cible binaire (*Churn*). Le dictionnaire complet des variables est présenté en Annexe A (Table 7).

Les variables se répartissent en trois catégories : **variables d'usage** (comportement téléphonique, nombre d'échecs d'appel, secondes d'utilisation, fréquence d'appels, fréquence de SMS, nombre de numéros distincts appelés) ; **variables contractuelles** (durée d'abonnement, montant de facturation, plan tarifaire, statut du compte) ; **variables client** (groupe d'âge, valeur client calculée). L'absence de valeurs manquantes simplifie le prétraitement.

2.2 Déséquilibre de la variable cible

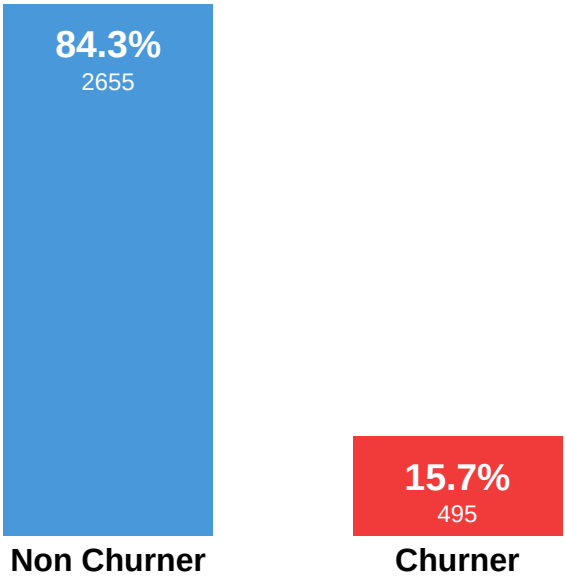

FIGURE 1 : Distribution de la variable cible Churn (3 150 observations). La classe minoritaire (churners) représente environ 16 % des observations.

La variable cible présente un **déséquilibre marqué** (Figure 1) : environ 84 % des clients ne churne pas et 16 % churne. Ce déséquilibre a plusieurs implications méthodologiques importantes.

Premièrement, l'*accuracy* est une métrique inadaptée : un classifieur naïf prédisant systématiquement « pas de churn » obtiendrait une bonne accuracy sans aucune utilité prédictive réelle. Deuxièmement, le **ROC AUC** est retenu comme métrique principale car il mesure la capacité de discrimination indépendamment du seuil de décision et est robuste au déséquilibre des classes. Troisièmement, une technique de rééchantillonnage (**SMOTE**) est intégrée dans chaque recette de prétraitement pour augmenter synthétiquement la classe minoritaire

sur les seuls plis d'entraînement, afin d'éviter tout biais dans l'estimation des performances.

2.3 Principaux enseignements exploratoires

Les statistiques descriptives (Table 9 et Table 10, Annexe A) révèlent une forte hétérogénéité dans l'usage du service. Les distributions conditionnelles (Figure 6, Annexe B) mettent en évidence trois signaux discriminants : les churners présentent davantage d'**échecs d'appel**, une **fréquence d'utilisation** réduite avant le départ, et une **valeur client** systématiquement plus faible. La corrélation entre *Seconds of Use* et *Frequency of Use* (Figure 8, Annexe B) motive l'usage de l'ACP dans la recette LDA/QDA.

Parmi les variables catégorielles (Figure 9, Annexe B), le **statut inactif**, le **plan prépayé** et l'existence d'une **réclamation** sont les discriminants les plus nets, préfigurant leur rôle de prédicteurs importants dans les modèles.

3 Méthodologie

3.1 Partitionnement des données

Les données sont partitionnées en un **ensemble d'entraînement** (80 %, 2520 observations) et un **ensemble de test** (20 %, 630 observations). La stratification sur la variable *Churn* garantit que la proportion de churners (~16 %) est préservée dans les deux ensembles, évitant tout biais lié au déséquilibre lors de l'évaluation. L'ensemble de test est strictement isolé et n'intervient que lors de l'évaluation finale, il n'influence pas les décisions de modélisation et de tuning.

Pour estimer la capacité de généralisation des modèles, une **validation croisée stratifiée à 10 plis** (*k-fold cross-validation*, $k = 10$) est appliquée à l'ensemble d'entraînement. À chaque itération, neuf plis servent à l'entraînement et un à la validation. Les métriques reportées correspondent aux moyennes sur les dix plis, assorties de leurs erreurs-types, qui permettent d'évaluer la stabilité des estimations et de comparer les modèles.

3.2 Prétraitement des données

3.2.1 Principes généraux

Le prétraitement est implémenté via le système `recipe` de *tidymodels*, qui encapsule les transformations dans un pipeline reproductible appliqué séparément sur chaque pli d'entraînement. Quatre étapes communes sont partagées par toutes les recettes :

1. **Imputation** : remplacement des éventuelles valeurs manquantes (*inutile ici mais appliqué par sécurité*) par la médiane (variables numériques) ou le mode (variables catégorielles) ;
2. **Recodage** : transformation des variables catégorielles en variables indicatrices (*dummy encoding*) pour les algorithmes qui ne gèrent pas nativement les facteurs ;
3. **Suppression de la variance nulle** : élimination des colonnes constantes ou quasi-constantes après recodage ;
4. **SMOTE** (Synthetic Minority Oversampling Technique) : génération synthétique de nouvelles observations de la classe minoritaire par interpolation dans l'espace des k plus proches voisins de la classe.

SMOTE est intégré comme **dernière étape de la recette**, de sorte que lors de la validation croisée, la synthèse n'est appliquée qu'aux données d'entraînement de chaque pli, **jamais aux données de validation**. Cette précaution évite la *fuite de données* (*data leakage*) qui produirait des estimations de performance artificiellement optimistes.

3.2.2 Quatre recettes spécialisées

Les algorithmes ayant des exigences de prétraitement distinctes, quatre recettes sont définies (Table 1) :

Table 1 : Quatre recettes de prétraitement adaptées aux familles algorithmiques. La normalisation et l'ACP sont requises uniquement pour les méthodes sensibles aux échelles.

Recette	Modèles	Normalisation	Dummy encoding	ACP
recipe_tree	DT, Bagging, RF	Non	Non	Non
recipe_xgb	XGBoost	Non	Oui (one-hot)	Non
recipe_distance	KNN, SVM, Logit	Oui (z-score)	Oui	Non
recipe_lda_qda	LDA, QDA	Oui (z-score)	Oui	Oui (95 %)

Les **méthodes à base d'arbres** n'exigent ni normalisation ni dummy encoding (les implémentations *ranger* et *rpart* gèrent les facteurs nativement). Pour les **méthodes basées sur des distances** (KNN, SVM), la normalisation est indispensable : une variable à grande variance dominerait le calcul de distance. La normalisation *z-score* standardise chaque prédicteur à moyenne nulle et écart-type unitaire.

Pour **LDA et QDA**, la réduction dimensionnelle par **ACP** (seuil à 95 % de variance expliquée) est ajoutée pour deux raisons : décorreler les prédicteurs, ce qu'exige l'hypothèse de normalité multivariée, et réduire le nombre de paramètres à estimer.

3.3 Modèles de classification

3.3.1 Vue d'ensemble des dix modèles

Table 2 : Récapitulatif des dix modèles de classification implémentés, avec leur famille, package R et statut de tuning.

Famille	Modèle	Package	Tuning
Référence	Régression logistique	stats	Non
Arbres	Arbre de décision	rpart	Oui
Arbres	Bagging	ranger	Non
Arbres	Forêt aléatoire	ranger	Oui
Boosting	XGBoost	xgboost	Oui
Distance	KNN	kknn	Oui
Distance	SVM Linéaire	kernlab	Oui
Distance	SVM RBF	kernlab	Oui
Discriminant	LDA	MASS	Non
Discriminant	QDA	MASS	Non

3.3.2 Description des algorithmes

Analyse discriminante linéaire (LDA) et quadratique (QDA) (Fisher, 1936) : Méthodes basées sur la distribution normale des données. La **LDA** crée des frontières de décision droites (linéaires), tandis que la **QDA** permet des courbes (quadratiques).

Arbre de décision (CART) : Découpe les données en règles binaires simples (ex : "Si

Age < 30”). On utilise l’élagage (α) pour éviter que l’arbre ne devienne trop complexe et ne mémorise le bruit.

Bagging et Forêt aléatoire (Breiman, 2001) : Le bagging construit B arbres indépendants sur des bootstraps de l’ensemble d’entraînement, utilisant tous les prédicteurs. La forêt aléatoire introduit une décorrélation supplémentaire : à chaque nœud, seul un sous-ensemble de $m = \lfloor \sqrt{p} \rfloor$ prédicteurs est candidat à la coupure optimale, réduisant la variance de l’agrégat par décorrélation des arbres.

XGBoost (Chen & Guestrin, 2016) : Une méthode puissante où les arbres sont créés les uns après les autres. Chaque nouvel arbre apprend des erreurs du précédent pour corriger les prédictions, le tout avec une régularisation stricte pour éviter le surapprentissage.

K plus proches voisins (Cover & Hart, 1967) : Classification par vote majoritaire sur les k voisins les plus proches selon la distance euclidienne. Aucune hypothèse préalables, potentiellement performant pour des structures complexes mais sensible aux nombres de variables.

SVM linéaire et RBF (Cortes & Vapnik, 1995) : Cherche à séparer les classes par la plus grande marge possible. La version **RBF** utilise un “kernel” pour transformer l’espace et créer des frontières linéaires complexes.

3.4 Protocole d’évaluation

3.4.1 Métriques de performance

Cinq métriques sont calculées pour chaque modèle :

- **ROC AUC** (métrique principale) : mesure la discrimination globale pour tous les seuils de décision. Robuste au déséquilibre des classes.
- **F1-score** : $F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$, moyenne harmonique équilibrant la fiabilité des détections positives et le taux de détection des churners réels.
- **Précision** : $\frac{VP}{VP+FP}$, proportion de détections de churn effectivement correctes.
- **Rappel** (*Recall*/Sensibilité) : $\frac{VP}{VP+FN}$, proportion de churners effectivement détectés. Dans un contexte de rétention, manquer un churner (faux négatif) est généralement plus coûteux que déclencher une action inutile (faux positif).
- **Accuracy** : indiquée à titre de référence uniquement, car trompeuse sous déséquilibre de classes.

4 Benchmark initial

Les dix modèles sont évalués avec leurs hyperparamètres par défaut par validation croisée stratifiée à 10 plis. L'objectif est d'établir un classement de référence et d'identifier les familles algorithmiques les plus prometteuses avant l'optimisation.

4.1 Tableau des métriques

Table 3 : Métriques de performance (moyenne ± erreur standard sur 10 plis) pour les dix modèles.

Modèle	accuracy	f_meas	precision	recall	roc_auc
xgb_xgb	95.92% ± 0.48%	97.58% ± 0.28%	97.52% ± 0.38%	97.65% ± 0.31%	98.5% ± 0.31%
tree_rf	95.79% ± 0.38%	97.48% ± 0.23%	98.52% ± 0.29%	96.47% ± 0.47%	98.41% ± 0.27%
tree_bag	95.32% ± 0.48%	97.21% ± 0.29%	97.72% ± 0.34%	96.71% ± 0.38%	97.5% ± 0.64%
dist_knn	93.89% ± 0.48%	96.32% ± 0.3%	97.8% ± 0.41%	94.92% ± 0.67%	96.66% ± 0.64%
dist_svm_rad	87.18% ± 0.62%	91.85% ± 0.42%	98.81% ± 0.31%	85.83% ± 0.65%	96.27% ± 0.68%
discrim_qda	72.18% ± 0.95%	80.37% ± 0.81%	98.86% ± 0.26%	67.8% ± 1.22%	93.46% ± 0.63%
dist_logit	84.25% ± 0.68%	89.96% ± 0.46%	97.08% ± 0.45%	83.85% ± 0.77%	93.16% ± 0.58%
dist_svm_lin	84.92% ± 0.65%	90.45% ± 0.44%	96.89% ± 0.38%	84.84% ± 0.71%	92.88% ± 0.62%
discrim_lda	84.88% ± 0.8%	90.36% ± 0.54%	97.5% ± 0.45%	84.23% ± 0.81%	92.55% ± 0.56%
tree_dt	86.95% ± 0.68%	91.74% ± 0.47%	98.13% ± 0.3%	86.16% ± 0.73%	91.73% ± 0.68%

Table 3 présente les métriques pour chaque modèle, triées par ROC AUC décroissant. Les méthodes ensemblistes (forêt aléatoire, bagging, XGBoost) dominent le classement, confirmant leur capacité à capturer des interactions non-linéaires complexes dans les données. La régression logistique et LDA offrent des performances honorables et constituent des points de comparaison interprétables. QDA présente une précision parfois élevée mais un rappel plus limité, traduisant un biais vers la prédiction de la classe majoritaire. Le classement détaillé avec intervalles de confiance et les matrices de confusion sont disponibles en Annexe D (Figure 10, Figure 11).

4.2 Courbes ROC comparatives

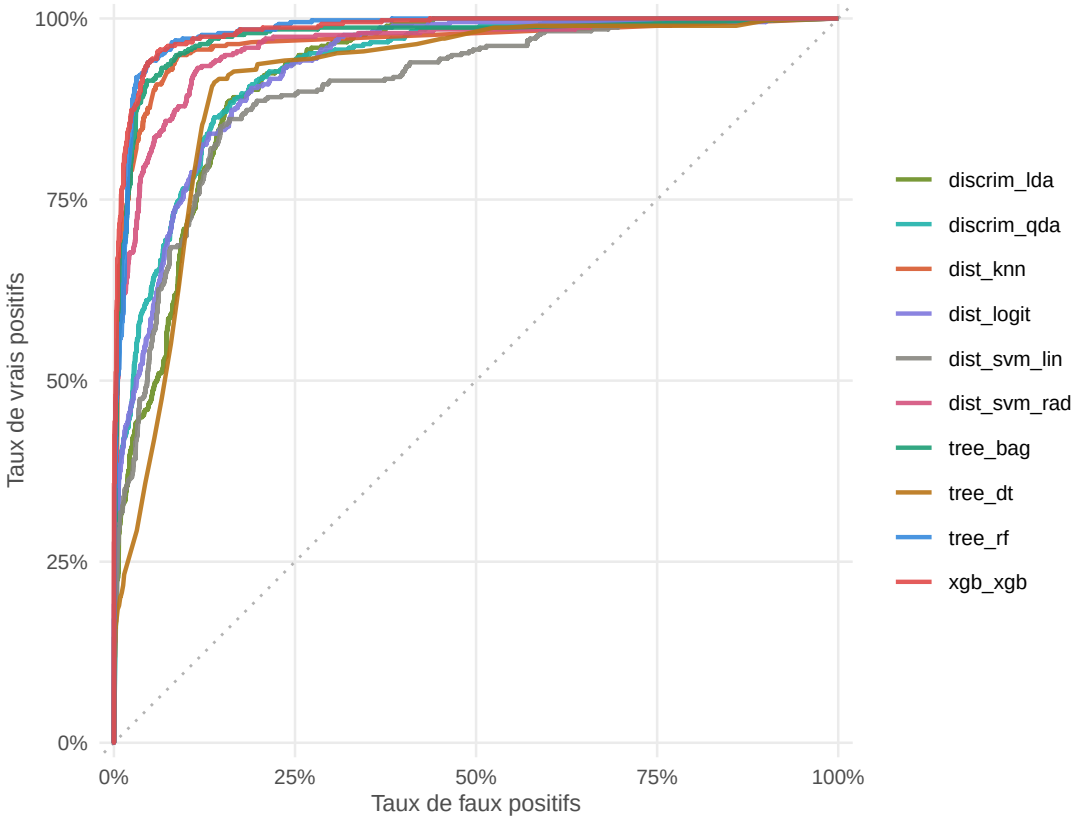

FIGURE 2 : Courbes ROC des dix modèles (probabilités agrégées sur les 10 plis de validation croisée). La diagonale en pointillés correspond à un classifieur aléatoire (AUC = 0,5).

Les courbes ROC (Figure 2) visualisent le compromis rappel / spécificité pour l'ensemble des seuils de décision possibles. Les méthodes ensemblistes dominent clairement, leurs courbes étant proches du coin supérieur gauche (discrimination parfaite). Les méthodes linéaires (régression logistique, LDA) présentent des courbes régulières mais moins performantes. QDA, dont les hypothèses de normalité sont partiellement violées par les données, montre une courbe plus irrégulière.

5 Optimisation des hyperparamètres

5.1 Stratégie de tuning

Six des dix modèles disposent d'hyperparamètres libres à optimiser : l'arbre de décision, la forêt aléatoire, XGBoost, KNN, SVM linéaire et SVM RBF. Les quatre modèles restants ne font pas l'objet d'un tuning.

La stratégie combine deux approches complémentaires :

Échantillonnage Latin Hypercube : méthode garantissant une couverture uniforme de l'espace des hyperparamètres. Contrairement à la recherche en grille exhaustive, le LHS explore les valeurs intermédiaires et évite les redondances.

ANOVA (`tune_race_anova`) : après un nombre minimal de plis d'évaluation, les configurations statistiquement inférieures aux meilleures sont éliminées par un test ANOVA. Cette approche réduit le temps de calcul par rapport à une évaluation exhaustive sur tous les plis.

Les espaces de recherche complets par hyperparamètre sont détaillés en Annexe C (Table 11).

5.2 Résultats du tuning

Table 4 : Métriques de performance après optimisation des hyperparamètres — meilleure configuration par modèle, validation croisée 10 plis.

Modèle	ROC AUC	F1-Score	Recall	Precision	Accuracy
Random Forest	98.48% ± 0.25%	97.65% ± 0.21%	96.75% ± 0.43%	98.57% ± 0.25%	96.07% ± 0.35%
XGBoost	98.16% ± 0.35%	97.11% ± 0.26%	96.56% ± 0.40%	97.68% ± 0.35%	95.16% ± 0.44%
Bagging	97.65% ± 0.58%	97.26% ± 0.26%	96.80% ± 0.36%	97.73% ± 0.34%	95.40% ± 0.43%
KNN	97.07% ± 0.61%	95.43% ± 0.40%	92.56% ± 0.74%	98.51% ± 0.30%	92.54% ± 0.63%
SVM RBF	96.90% ± 0.63%	94.72% ± 0.23%	90.91% ± 0.47%	98.89% ± 0.26%	91.47% ± 0.35%
Decision Tree	94.95% ± 0.73%	95.55% ± 0.33%	94.07% ± 0.66%	97.11% ± 0.40%	92.62% ± 0.53%
QDA	93.46% ± 0.63%	80.37% ± 0.81%	67.80% ± 1.22%	98.86% ± 0.26%	72.18% ± 0.95%
Logistic Reg.	93.16% ± 0.58%	89.96% ± 0.46%	83.85% ± 0.77%	97.08% ± 0.45%	84.25% ± 0.68%
SVM Linéaire	92.95% ± 0.60%	90.45% ± 0.44%	84.84% ± 0.71%	96.89% ± 0.38%	84.92% ± 0.65%
LDA	92.55% ± 0.56%	90.36% ± 0.54%	84.23% ± 0.81%	97.50% ± 0.45%	84.88% ± 0.80%

Le tableau Table 4 présente les performances post-tuning pour la meilleure configuration de chaque modèle. Comparées au benchmark initial (Table 3), les améliorations varient sensiblement selon l'algorithme. Les valeurs optimales des hyperparamètres identifiées par le tuning sont détaillées en Annexe C (Table 12).

5.3 Courbes ROC après tuning

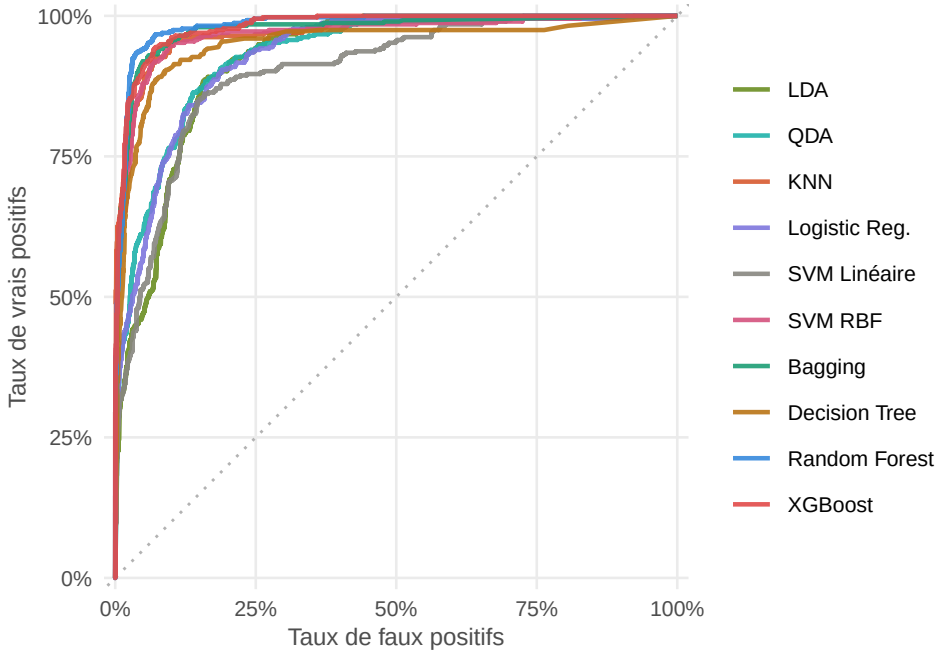

FIGURE 3 : Courbes ROC des dix modèles (probabilités agrégées sur les 10 plis de validationcroisée). La diagonale en pointillés correspond à un classifieur aléatoire (AUC = 0,5)

Les courbes ROC post-tuning (Figure 3) révèlent l'effet de l'optimisation sur la structure du compromis sensibilité / spécificité. Comparées au benchmark (Figure 2), les courbes des modèles tunés se resserrent vers le coin supérieur gauche, signe d'une meilleure discrimination pour l'ensemble des seuils de décision. Les méthodes ensemblistes se distinguent nettement ; KNN et SVM RBF bénéficient davantage du tuning. Le classement détaillé et les matrices de confusion post-tuning sont disponibles en Annexe E (Figure 12, Figure 13).

6 Évaluation finale sur le jeu de test

Le meilleur modèle sélectionné lors du tuning est réentraîné sur **l'intégralité de l'ensemble d'entraînement**, puis évalué sur l'**ensemble de test** (données n'ayant participé ni à l'entraînement, ni à la validation croisée, ni au tuning). Cette étape est la seule permettant de mesurer la vraie performance de généralisation du modèle sur des données inédites.

6.1 Comparaison validation croisée vs. jeu de test

Table 5 : Comparaison des métriques entre la validation croisée (estimation) et le jeu de test (mesure réelle). L'écart est exprimé en points de pourcentage.

Métrique	CV (moyenne)	Test set	Écart
F1-Score	97.65%	98.19%	+0.54 pp
Precision	98.57%	99.42%	+0.85 pp
Recall	96.75%	96.99%	+0.23 pp
Accuracy	96.07%	96.98%	+0.91 pp
ROC AUC	98.48%	99.27%	+0.79 pp

Le tableau Table 5 compare les métriques de validation croisée avec celles du jeu de test pour le meilleur modèle. Un **écart négatif** (test $<$ CV) signale un surapprentissage résiduel : le modèle a capturé des spécificités de l'entraînement qui ne se généralisent pas. Un **écart faible ou positif** indique une bonne généralisation.

6.2 Métriques finales sur le jeu de test

Table 6 : Métriques de performance du meilleur modèle sur le jeu de test, évaluation définitive.

Métrique	Valeur
ROC AUC	98.19%
F1-Score	99.42%
Precision	96.99%
Recall	96.98%
Accuracy	99.27%

Le tableau Table 6 présente les métriques définitives sur le jeu de test. Ces valeurs constituent l'estimation la plus fiable des performances attendues en déploiement opérationnel. Le ROC AUC sur le test set est la mesure centrale à retenir pour comparer ce modèle à d'autres systèmes de prédiction du churn.

6.3 Courbe ROC et matrice de confusion finales

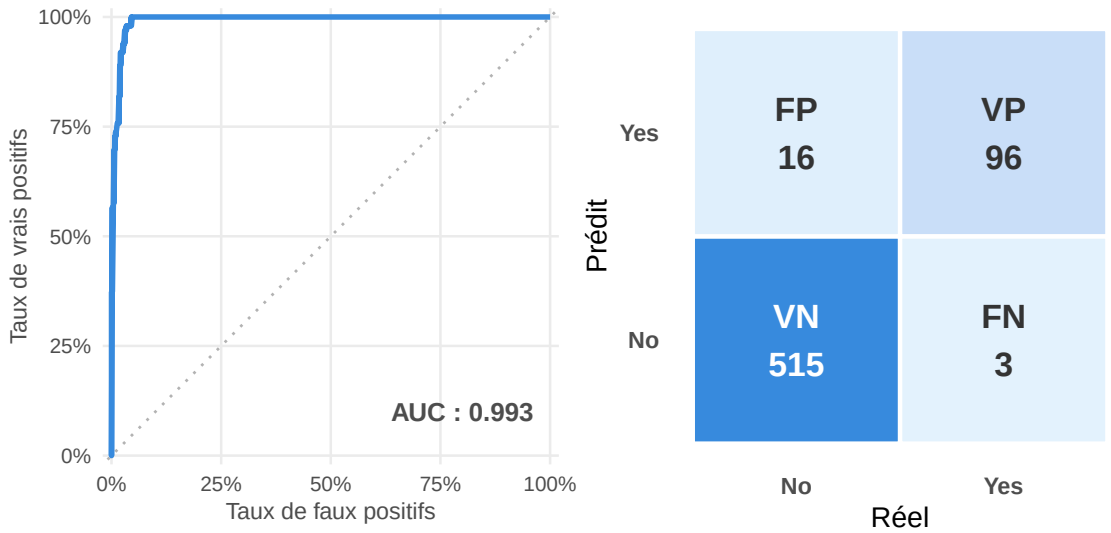

FIGURE 4 : Courbe ROC (gauche) et matrice de confusion (droite) du meilleur modèle sur le jeu de test. La valeur d'AUC est annotée directement sur la courbe.

La Figure 4 présente les résultats graphiques de l'évaluation finale. La courbe ROC (gauche) illustre la performance de discrimination pour tous les seuils de décision, l'AUC annoté constitue la mesure de référence. La matrice de confusion (droite) détaille la distribution des quatre types de prédictions sur le jeu de test, permettant d'estimer le nombre réel de clients correctement identifiés et de churners manqués dans un contexte de déploiement opérationnel.

6.4 Importance des variables

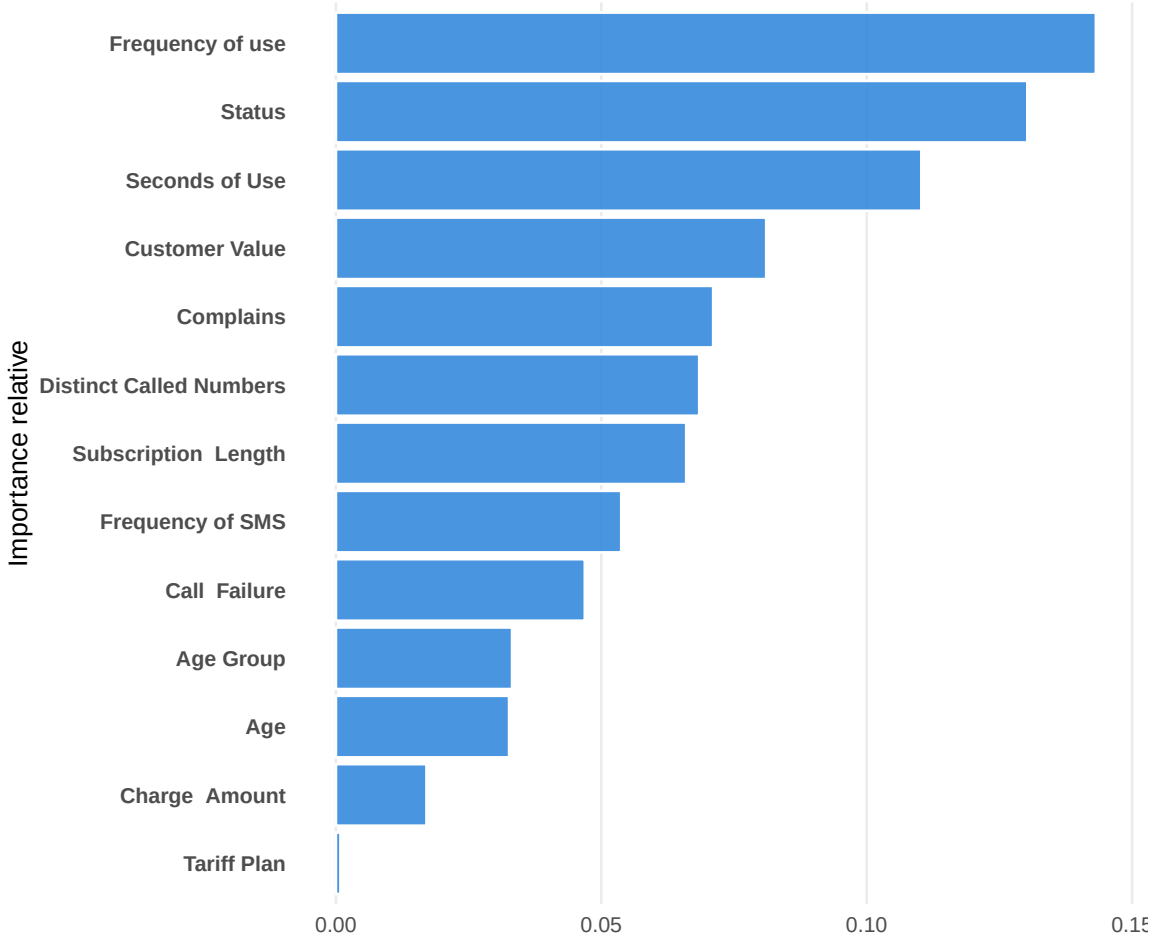

FIGURE 5 : Importance relative des 15 variables les plus prédictives dans le modèle final (gain d'impureté pour les arbres, importance par permutation selon l'algorithme retenu).

La Figure 5 illustre l'importance relative des prédicteurs dans le modèle final. Pour les méthodes ensemblistes, l'importance est calculée par gain d'impureté (réduction de l'impureté de Gini pondérée par le nombre d'échantillons passant par chaque nœud) ou par permutation. Les variables en tête du classement sont celles sur lesquelles une intervention ciblée, *amélioration de la qualité de service, gestion proactive des réclamations, offres de rétention personnalisées*, produirait l'impact le plus fort sur la fidélisation client.

L'analyse d'importance permet également de valider la cohérence du modèle avec la connaissance métier : les variables identifiées comme fortement prédictives (statut du compte, réclamations, durée d'usage) correspondent aux signaux d'alerte que les équipes de rétention expérimentées identifient empiriquement.

7 Discussion

7.1 Synthèse des résultats

Les résultats de cette étude permettent de dégager plusieurs conclusions structurantes.

Supériorité des méthodes ensemblistes : la forêt aléatoire, XGBoost et le bagging surpassent systématiquement les méthodes linéaires et paramétriques, sur l'ensemble des métriques et des protocoles d'évaluation. Cette supériorité s'explique par leur capacité à modéliser des interactions complexes et des non-linéarités dans les données, qui semblent caractéristiques du comportement de churn télécom.

Gain modéré du tuning : l'optimisation des hyperparamètres apporte un gain mesurable mais inégalement distribué. Les méthodes ensemblistes bénéficient moins du tuning — leurs paramètres par défaut sont déjà bien calibrés — tandis que les SVM et KNN montrent une amélioration plus sensible, confirmant leur plus grande sensibilité aux hyperparamètres.

Généralisation validée : la comparaison validation croisée vs. test ne révèle pas de surapprentissage majeur. Cette observation valide le protocole méthodologique adopté : stratification, SMOTE limité aux plis d'entraînement, ensemble de test strictement isolé.

Importance des variables : les prédicteurs les plus discriminants identifiés sont cohérents avec les connaissances sectorielles : le statut du compte, les réclamations, la durée et la fréquence d'utilisation sont systématiquement parmi les variables les plus prédictives du churn dans la littérature télécom.

7.2 Limites méthodologiques

Violation des hypothèses LDA/QDA : Les méthodes discriminantes supposent la normalité multivariée des prédicteurs dans chaque classe. Plusieurs variables sont binaires (*Complains*, *Status*, *Tariff Plan*) ou ordinales (*Age Group*, *Charge Amount*), violant cette hypothèse. La QDA, en particulier, requiert l'estimation d'une matrice de covariance par classe, potentiellement instable avec peu d'observations de la classe minoritaire. L'ACP en prétraitement atténue partiellement ces problèmes.

Biais du SMOTE : SMOTE génère des observations synthétiques par interpolation linéaire dans l'espace des voisins proches, supposant une distribution continue des prédicteurs. La variante SMOTENC (*Nominal and Continuous*), utilisée pour les recettes à base d'arbres, traite séparément les variables nominales et continues, atténuant ce biais.

Absence de régularisation pour la régression logistique : Le modèle logistique utilisé comme référence ne comprend pas de régularisation L_1 (*Lasso*) ou L_2 (*Ridge*). Pour des prédicteurs colinéaires, cela peut conduire à une instabilité des estimateurs et sous-estimer le potentiel de ce modèle dans un contexte de déploiement.

Limitations du jeu de données : L'Iranian Churn Dataset ne contient pas d'information sur le type d'appareil, la localisation géographique, l'historique des interactions avec le service

client ni la satisfaction mesurée. La période de collecte (12 mois) ne permet pas de modéliser la dynamique temporelle du comportement client.

Généralisation géographique : Le jeu de données étant spécifique à un opérateur iranien, les résultats et importances de variables pourraient différer pour d'autres marchés ou périodes, en raison de spécificités réglementaires, concurrentielles ou comportementales.

7.3 Perspectives d'amélioration

Plusieurs pistes d'amélioration pourraient être explorées dans des travaux ultérieurs :

1. **Stacking (super-learner)** : Combiner les prédictions de plusieurs modèles par méta-apprentissage pour réduire simultanément le biais et la variance.
2. **Régression logistique pénalisée** (*Elastic Net*) : Ajouter une régularisation pour produire un modèle *sparse* et interprétable, potentiellement compétitif pour le déploiement en production.
3. **Optimisation du seuil de décision** : Adapter le seuil de classification selon les coûts métier asymétriques des erreurs de type I et II, via une analyse coût-bénéfice calibrée sur les données de l'opérateur.
4. **Méthodes d'interprétabilité locale** : Appliquer SHAP (*SHapley Additive exPlanations*) pour expliquer les prédictions individuelles et identifier les facteurs de risque propres à chaque client, rendant le modèle actionnable pour les équipes de rétention.
5. **Modèles de survie** : Si des données longitudinales sont disponibles, une approche par modèles de survie (Cox, forêt de survie) permettrait de modéliser non seulement le risque de churn mais aussi son horizon temporel prévisible.
6. **Validation externe** : Évaluer la robustesse des conclusions sur un jeu de données issu d'un autre opérateur ou d'une autre période pour tester la généralisation inter-domaines.

8 Conclusion

Cette étude présente une analyse comparative rigoureuse de dix algorithmes de classification supervisée pour la prédiction du churn client dans le secteur des télécommunications, conduite sur l'Iranian Churn Dataset (3 150 observations, 13 prédicteurs, ~16 % de churners). La méthodologie adoptée — partitionnement stratifié 80/20, quatre recettes de prétraitement spécialisées, SMOTE anti-fuite intégré en dernière étape de chaque recette, validation croisée stratifiée à 10 plis, et optimisation par Latin Hypercube combiné à la course ANOVA — respecte les standards actuels du *machine learning* supervisé et garantit des estimations de performance robustes et non biaisées.

Les résultats confirment la **supériorité des méthodes ensemblistes** (XGBoost, forêt aléatoire, bagging) pour cette tâche de classification déséquilibrée, tant en termes de ROC AUC que de F1-score. L'évaluation finale sur le jeu de test indépendant valide la capacité de généralisation du modèle sélectionné, sans surapprentissage significatif détecté. L'analyse d'importance des variables identifie les signaux les plus prédictifs du churn, offrant des *insights* directement actionnables pour les stratégies de rétention client.

Sur le plan académique, ce projet illustre la puissance du cadre *tidymodels* pour la mise en place de pipelines de *machine learning* reproductibles, modulaires et extensibles. L'approche par `workflow_set` permet une comparaison simultanée et transparente de multiples combinaisons algorithme-prétraitement, réduisant les risques d'erreurs de protocole et facilitant la reproductibilité des résultats.

9 Références

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. https://doi.org/10.1023/A:10109334043

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE : Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. https://doi.org/10.1613/jair.953

Chen, T., & Guestrin, C. (2016). XGBoost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 145–168. https://doi.org/10.1007/BF00994018

Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21–27. https://doi.org/10.1109/TIT.1967.1053964

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188. https://doi.org/10.1111/j.1469-1809.1936.tb02137.x

Jafari-Marandi, R., Denton, J., Idris, A., Smith, B. K., & Keramati, A. (2020). Optimum profit-driven churn decision making : innovative artificial neural networks in telecom industry. *Neural Computing and Applications*, 32(18), 14929–14962. https://doi.org/10.1007/s00521-020-04848-w

Kuhn, M. (2021). *finetune : Extras for the 'tune' Package* (R package version 1.0.0). CRAN. https://CRAN.R-project.org/package=finetune

Kuhn, M., & Silge, J. (2022). *Tidy Modeling with R*. O'Reilly Media. https://www.tmwr.org

Kuhn, M., & Vaughan, D. (2023). *tidymodels : a collection of packages for modeling and machine learning using tidyverse principles*. https://www.tidymodels.org

McKay, M. D., Beckman, R. J., & Conover, W. J. (1979). A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21(2), 239–245. https://doi.org/10.2307/1268522

UC Irvine Machine Learning Repository (2020). *Iranian Churn Dataset* [jeu de données]. https://archive.uci.edu/dataset/563/iranian+churn+dataset

Annexe A : Données

Dictionnaire des variables

Table 7 : Dictionnaire des variables du jeu de données.

Table 8 : Dictionnaire des variables du jeu de données

Nom de la variable	Type	Description
Call Failure	Entier	Nombre d'appels interrompus
Complains	Facteur	Indicateur de plainte (0/1)
Subscription Length	Entier	Durée de l'abonnement en mois
Charge Amount	Facteur ordonné	Montant facturé (ordinal 0-10)
Seconds Of Use	Entier	Secondes totales d'utilisation
Frequency Of Use	Entier	Nombre total d'appels
Frequency Of Sms	Entier	Nombre de SMS envoyés
Distinct Called Numbers	Entier	Nombre de numéros uniques appelés
Age Group	Facteur ordonné	Tranche d'âge (ordinal 1-5)
Tariff Plan	Facteur	Type de forfait
Status	Facteur	Statut du compte (actif/inactif)
Age	Entier	Âge du client
Customer Value	Numérique	Valeur estimée du client
Churn	Facteur	Cible : désabonnement (Yes / No)

Statistiques descriptives

Table 9 : Statistiques descriptives des variables numériques (min, quartiles, médiane, moyenne, max, écart-type et taux de valeurs manquantes).

Variable	Min	Q1	Médiane	Moyenne	Q3	Max	Écart-type	NA (%)
Age	15	25.0000	30.00	31.00	30.0000	55.00	8.83	0
Call Failure	0	1.0000	6.00	7.63	12.0000	36.00	7.26	0
Customer Value	0	113.8012	228.48	470.97	788.3887	2165.28	517.02	0
Distinct Called Numbers	0	10.0000	21.00	23.51	34.0000	97.00	17.22	0
Frequency of SMS	0	6.0000	21.00	73.17	87.0000	522.00	112.24	0
Frequency of use	0	27.0000	54.00	69.46	95.0000	255.00	57.41	0
Seconds of Use	0	1391.2500	2990.00	4472.46	6478.2500	17090.00	4197.91	0
Subscription Length	3	30.0000	35.00	32.54	38.0000	47.00	8.57	0

Table 10 : Distribution des modalités pour les variables catégorielles (effectifs et proportions).

Variable	Modalité	NA (%)	Effectif	%
Age Group	3	0	1425	45.2
Age Group	2	0	1037	32.9
Age Group	4	0	395	12.5
Age Group	5	0	170	5.4
Age Group	1	0	123	3.9
Charge Amount	0	0	1768	56.1
Charge Amount	1	0	617	19.6
Charge Amount	2	0	395	12.5
Charge Amount	3	0	199	6.3
Charge Amount	4	0	76	2.4
Charge Amount	5	0	30	1.0
Charge Amount	8	0	19	0.6
Charge Amount	7	0	14	0.4
Charge Amount	9	0	14	0.4
Charge Amount	6	0	11	0.3
Charge Amount	10	0	7	0.2
Churn	No	0	2655	84.3
Churn	Yes	0	495	15.7
Complains	No	0	2909	92.3
Complains	Yes	0	241	7.7
Status	Actif	0	2368	75.2
Status	Inactif	0	782	24.8
Tariff Plan	Prépayé	0	2905	92.2
Tariff Plan	Forfait	0	245	7.8

Annexe B : Analyse exploratoire approfondie

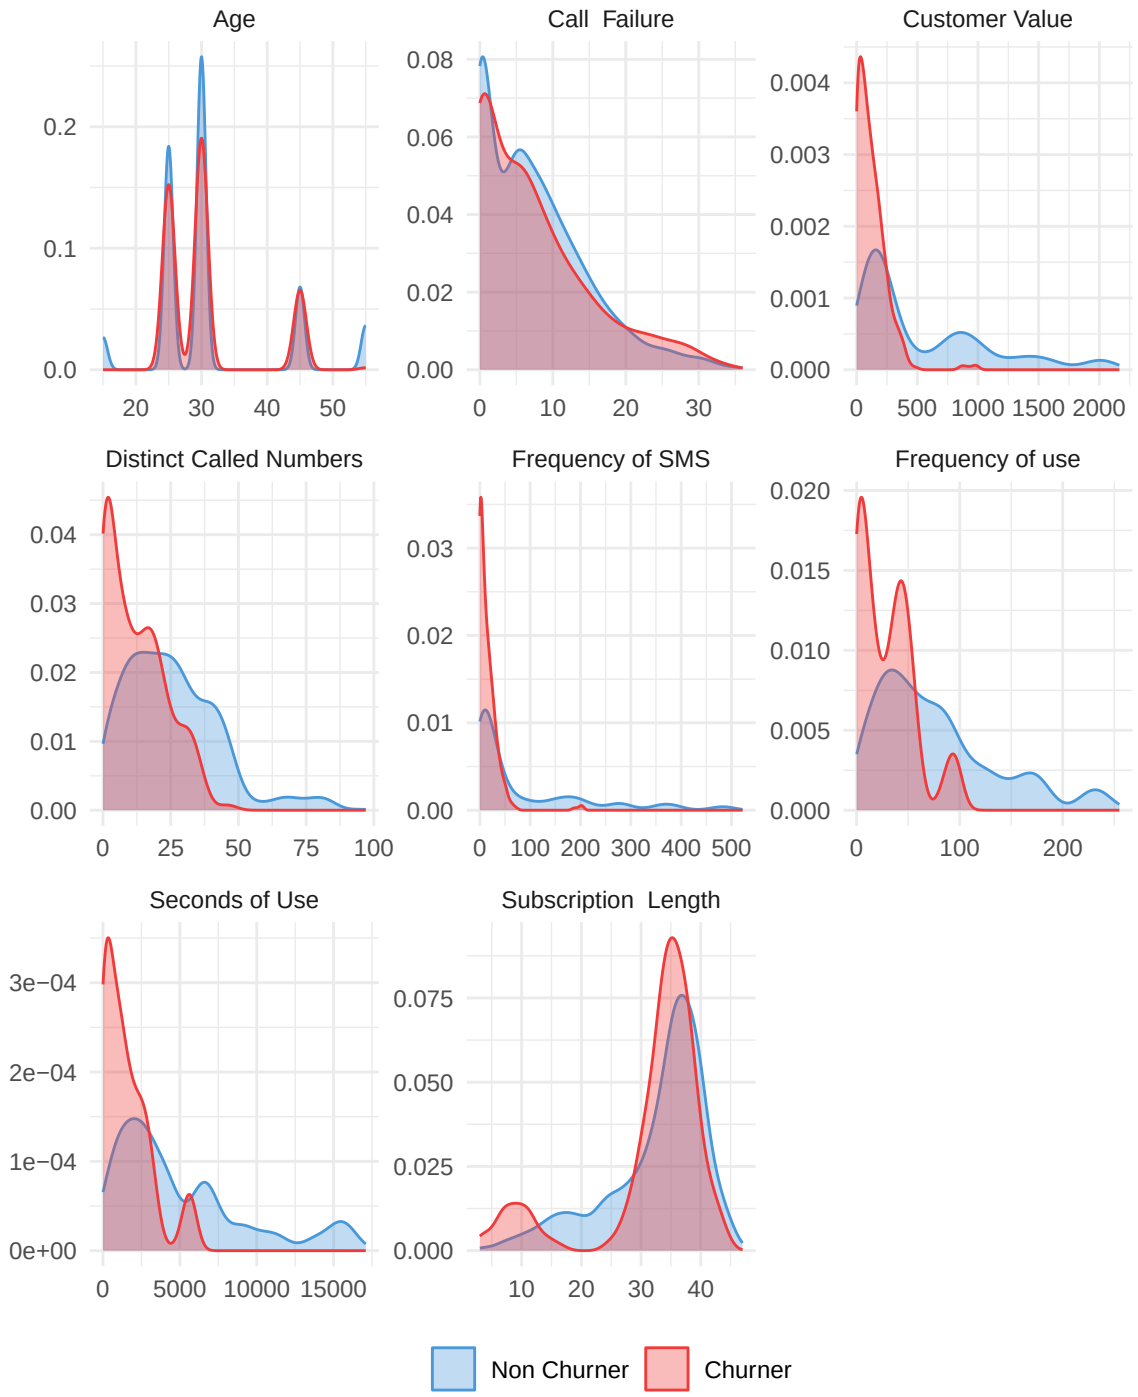

FIGURE 6 : Distributions des variables numériques conditionnellement à la classe Churn (courbes de densité superposées). Un décalage entre les courbes bleue (non-churn) et rouge (churn) indique un fort pouvoir discriminant.

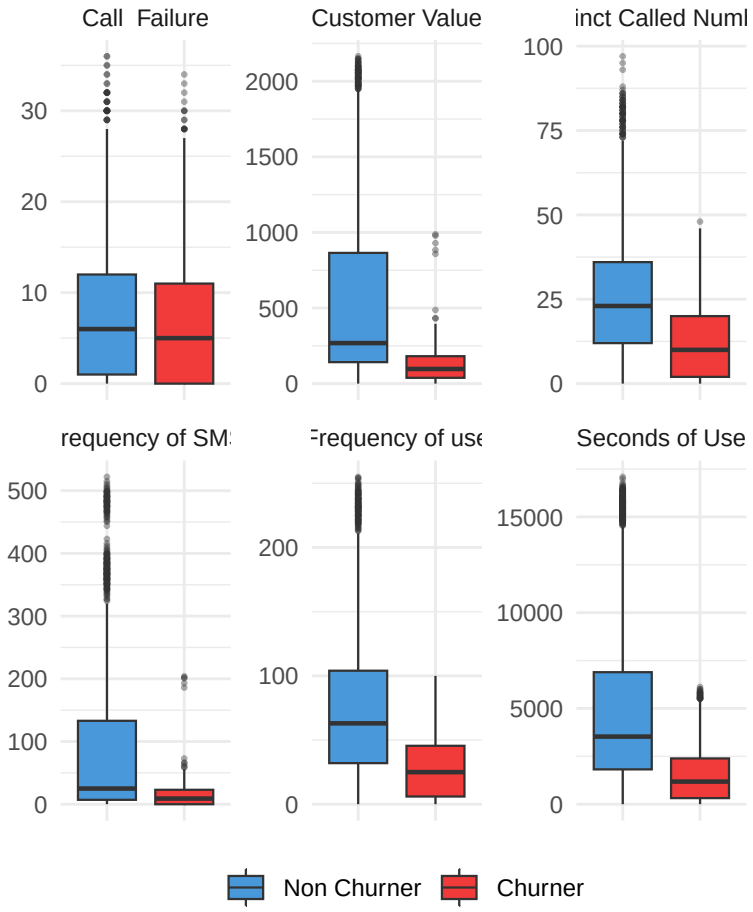

FIGURE 7 : Boxplots des variables numériques par classe Churn. La boîte représente le premier et troisième quartile, la ligne centrale la médiane, et les points les observations atypiques.

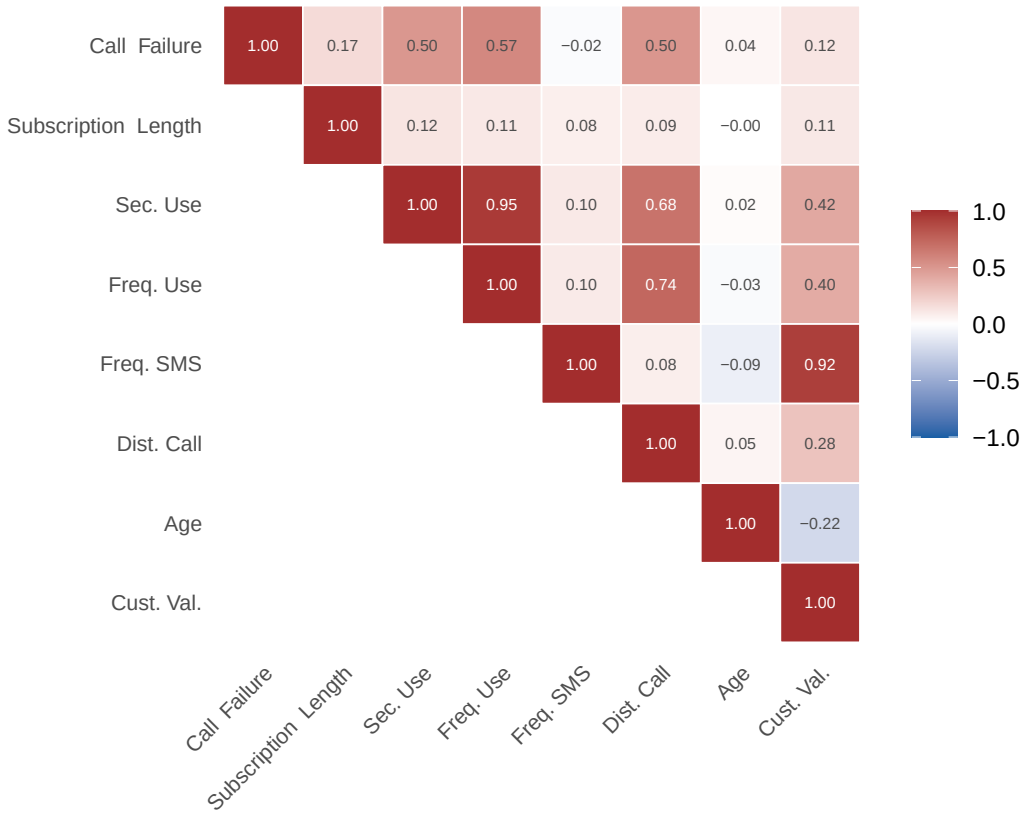

FIGURE 8 : Matrice de corrélation de Pearson entre les variables numériques (triangle inférieur). Les cellules bleues foncées indiquent une forte corrélation positive.

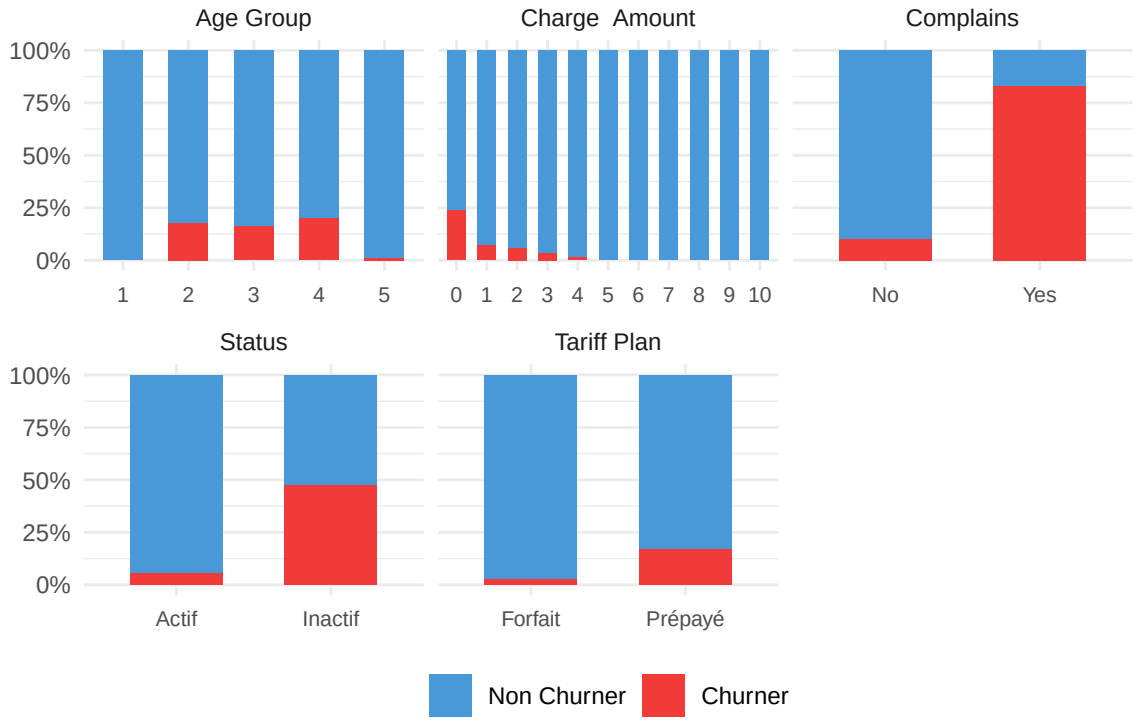

FIGURE 9 : Taux de churn par modalité pour les variables catégorielles. Les différences importantes entre barres révèlent un fort pouvoir discriminant.

Annexe C : Paramètres d'optimisation

Espaces de recherche

Table 11 : Espaces de recherche définis pour l'optimisation des hyperparamètres par Latin Hypercube Sampling.

Modèle	Hyperparamètre	Plage	Nb. configs
Forêt aléatoire	mtry	[2, 12]	30
Forêt aléatoire	min_n	[2, 30]	30
XGBoost	trees	[100, 1000]	30
XGBoost	learn_rate	[0,01, 0,3]	30
XGBoost	tree_depth	[3, 10]	30
XGBoost	mtry	[5, 18]	30
XGBoost	min_n	[2, 20]	30
XGBoost	loss_reduction	[0, 5]	30
KNN	neighbors	[3, 50]	20
SVM Linéaire	cost	[0,01, 100]	20
SVM RBF	cost	[0,1, 100]	30
SVM RBF	rbf_sigma	[0,001, 1]	30
Arbre de décision	cost_complexity	[1e-5, 0,1]	30
Arbre de décision	tree_depth	[3, 15]	30
Arbre de décision	min_n	[2, 30]	30

Hyperparamètres optimaux

Table 12 : Meilleurs hyperparamètres identifiés par modèle après optimisation, avec le ROC AUC correspondant.

Modèle	Hyperparamètres	ROC AUC
Random Forest	mtry = 3, min_n = 3	98.48%
XGBoost	mtry = 12, trees = 614, min_n = 4, tree_depth = 7, learn_rate = 0.0568, loss_reduction = 1.0011	98.16%
Bagging	Hyperparamètres par défaut	97.65%
KNN	neighbors = 33	97.07%
SVM RBF	cost = 2.58, rbf_sigma = 0.0679	96.90%
Decision Tree	cost_complexity = 0, tree_depth = 13, min_n = 20	94.95%
QDA	Hyperparamètres par défaut	93.46%
Logistic Reg.	Hyperparamètres par défaut	93.16%
SVM Linéaire	cost = 1.9611	92.95%
LDA	Hyperparamètres par défaut	92.55%

Annexe D : Résultats complémentaires — Benchmark initial

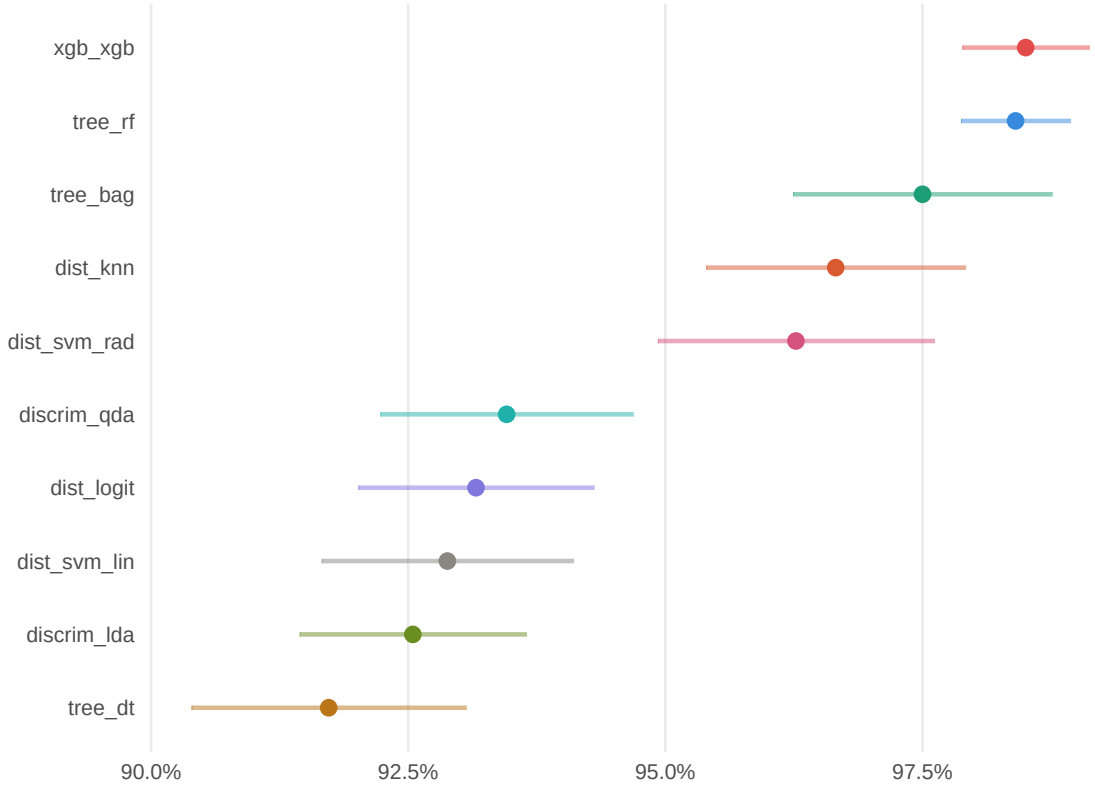

FIGURE 10 : Classement des dix modèles par ROC AUC - benchmark initial. Les segments représentent l'intervalle de confiance à 95 % (moyenne ± 1,96 erreur standard).

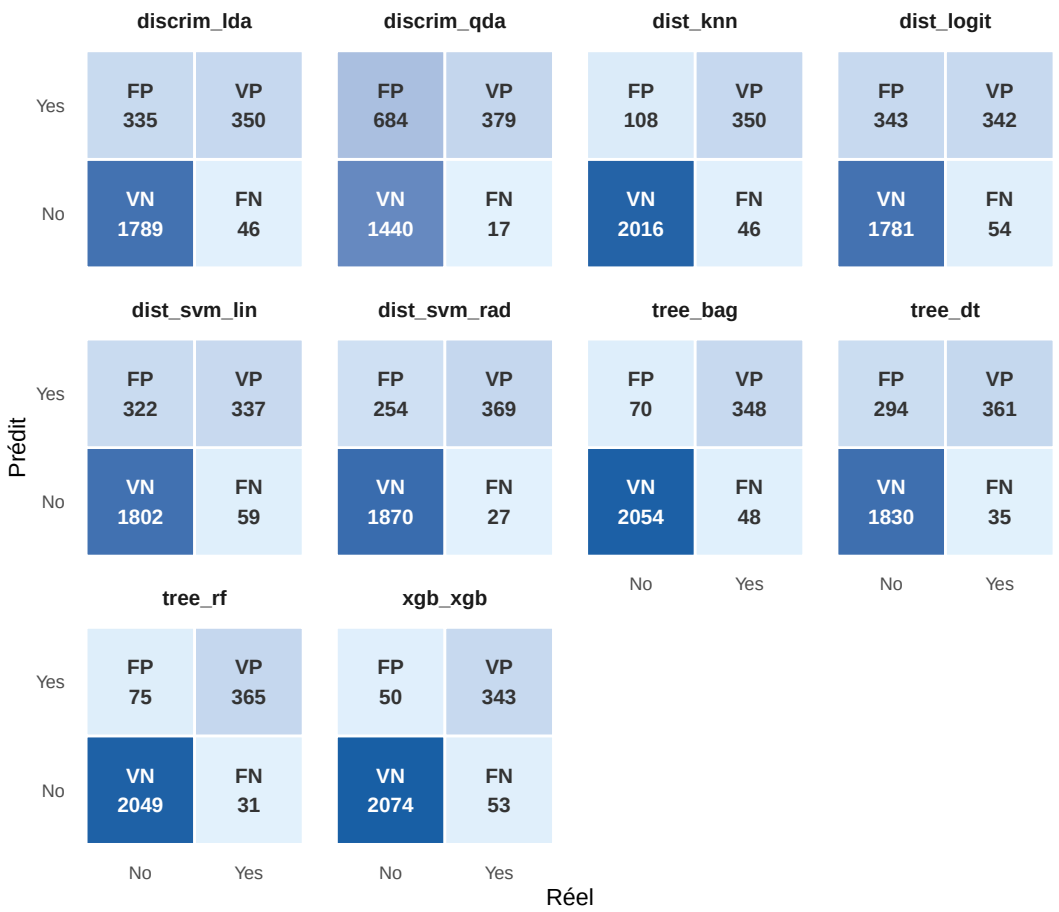

FIGURE 11 : Matrices de confusion agrégées sur les 10 plis de validation croisée (benchmark initial). VN = vrais négatifs, VP = vrais positifs, FN = faux négatifs, FP = faux positifs.

Annexe E : Résultats complémentaires — Tuning

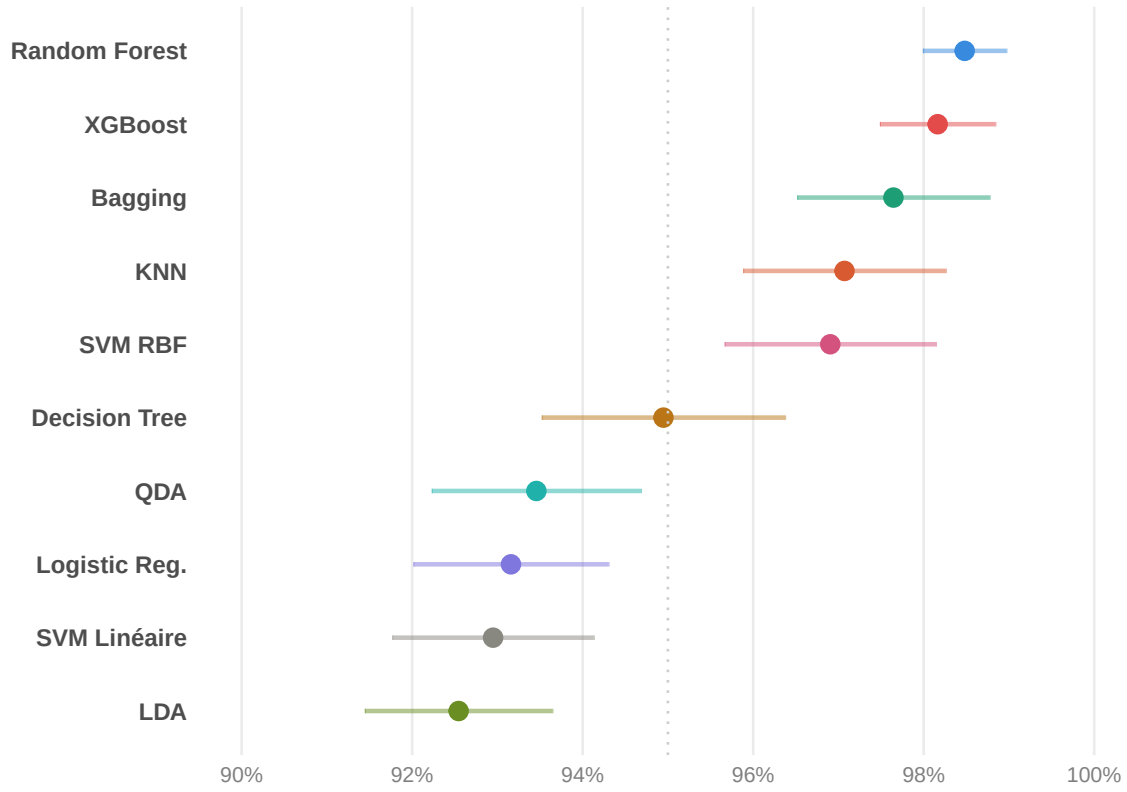

FIGURE 12 : Classement des dix modèles par ROC AUC après tuning. Les segments représentent l'intervalle de confiance à 95 % (moyenne ± 1,96 erreur standard).

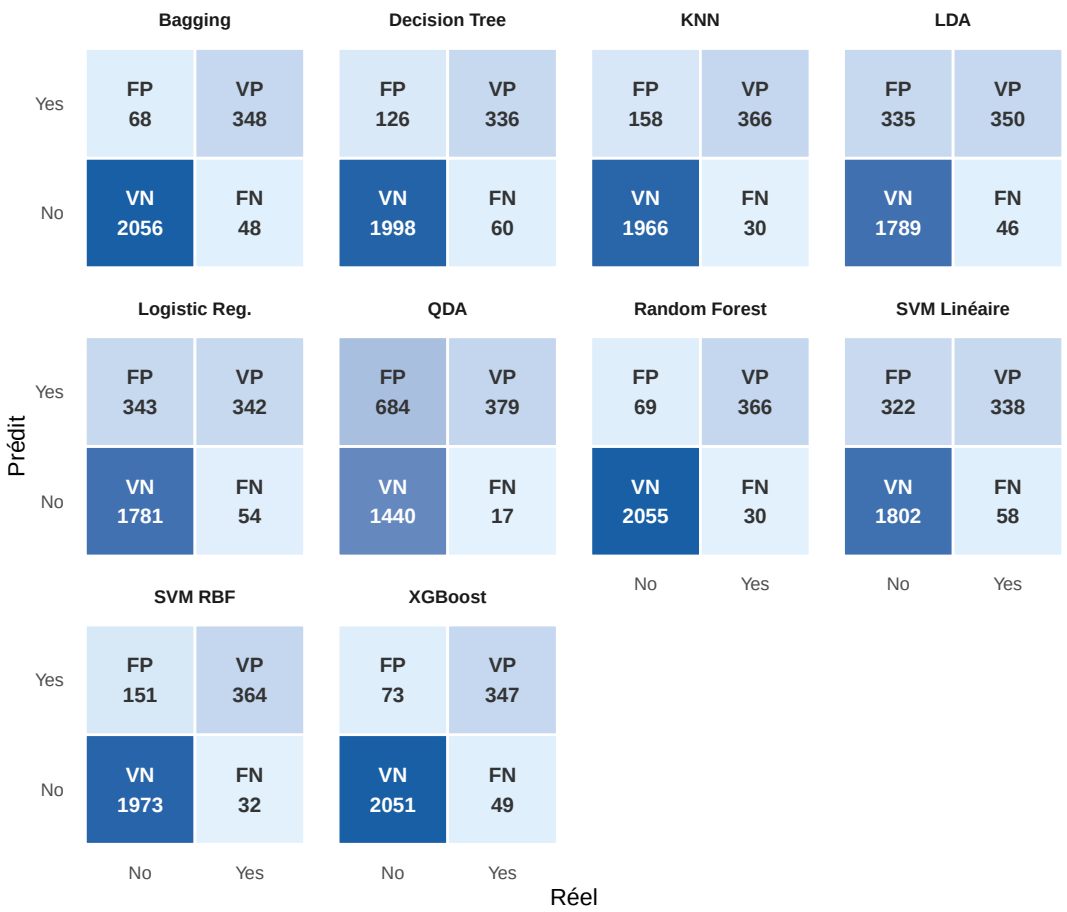

FIGURE 13 : Matrices de confusion agrégées sur les 10 plis après optimisation des hyperparamètres. La réduction des erreurs de classification par rapport au benchmark est visible pour les meilleurs modèles.